



ΑΡΙΣΤΟΤΕΛΕΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΕΣΣΑΛΟΝΙΚΗΣ

ΤΜΗΜΑ ΠΛΗΡΟΦΟΡΙΚΗΣ

Χρήση Συνελεκτικού Δικτύου για την Ανίχνευση Επιληπτικών
Σημάτων σε Ηλεκτροκεφαλογραφήματα

Πτυχιακή Εργασία

Φυσέκης Θωμάς
Α.Ε.Μ.:3770

Επιβλέπων: Λάσκαρης Νίκος,
Αναπληρωτής Καθηγητής Α.Π.Θ.

Μάιος, 2024

Περίληψη

Η επιληψία αποτελεί μια μακροχρόνια ασθένεια του κεντρικού νευρικού συστήματος, η οποία διαταράσσει την φυσιολογική λειτουργία και οδηγεί σε επαναλαμβανόμενες κρίσεις. Κατά τη διάρκεια των επιληπτικών κρίσεων, παρατηρούνται προσωρινές ανωμαλίες στην ηλεκτρική δραστηριότητα του εγκεφάλου, οι οποίες μπορεί να προκαλέσουν διάφορα συμπτώματα, όπως απώλεια προσοχής και μνήμης, ή ακόμη και σπασμούς σε ολόκληρο το σώμα. Σε πολλές περιπτώσεις, η χρήση αντιεπιληπτικών φαρμάκων δεν αρκεί για να ελέγξει τις κρίσεις, και αυτό αποτελεί σοβαρό κίνδυνο για τραυματισμούς, περιορίζει την ανεξαρτησία και την κινητικότητα των ατόμων και επηρεάζει αρνητικά την κοινωνική τους ζωή και την οικονομική τους κατάσταση. Για τη διάγνωση της επιληψίας, συνήθως χρησιμοποιείται το ηλεκτροεγκεφαλογράφημα, το οποίο ανιχνεύει μικρές ανωμαλίες που ονομάζονται επιληπτικές εκφορτίσεις και βοηθούν στον εντοπισμό του προβλήματος.

Η παρούσα πτυχιακή διαπραγματεύεται τεχνικές για τον εντοπισμό της έναρξης των εκφορτίσεων από την ηλεκτροεγκεφαλογραφία, με στόχο την ανάπτυξη ενός μοντέλου CNN (Συνελικτικό Νευρωνικό Δίκτυο). Στο πλαίσιο αυτής της πτυχιακής εργασίας, τα δεδομένα που χρησιμοποιήθηκαν προέρχονται από τη μελέτη που δημοσιεύτηκε αρχικά στο άρθρο των Andrzejak, Ralph G. και συνεργατών το 2001. Οι κατηγορίες δεδομένων περιλαμβάνουν καταγραφές από κανονικούς εθελοντές με ανοικτά και κλειστά μάτια, καθώς και καταγραφές από ασθενείς με επιληψία, τόσο ελεύθερους από κρίσεις όσο και κατά τη διάρκεια κρίσεων. Τα δεδομένα αυτά προσφέρουν μια ευκαιρία να εξεταστεί η ανάπτυξη μοντέλων μηχανικής μάθησης για την πρόβλεψη της έναρξης επιληπτικών εκφορτίσεων από την ηλεκτροεγκεφαλογραφία.

Φυσέκης Θωμάς
Τμήμα Πληροφορικής,
Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης, Ελλάδα

Abstract

Epilepsy is a chronic disorder of the central nervous system that disrupts normal function and leads to recurrent seizures. During epileptic seizures, temporary abnormalities in the brain's electrical activity occur, which can cause various symptoms such as loss of attention and memory, sensory variations, or even spasms throughout the body. In many cases, the use of antiepileptic drugs is not sufficient to control seizures, posing a serious risk of injury, limiting independence and mobility, and negatively affecting individuals' social and economic well-being. Electroencephalogram (EEG) is commonly used for epilepsy diagnosis, detecting small abnormalities called epileptic discharges that aid in identifying the problem.

This thesis explores techniques for detecting the onset of seizures from EEG data, with a particular focus on developing a Convolutional Neural Network (CNN) model. The data used in this study are sourced from the research published by Andrzejak, Ralph G., and colleagues in 2001. The data categories include recordings from normal volunteers with eyes open and closed, as well as recordings from patients with epilepsy, both seizure-free and during seizures. These data provide an opportunity to explore the development of machine learning models for predicting the onset of epileptic discharges from EEG signals.

Fysekis Thomas
Computer Science,
Aristotle University of Thessaloniki, Greece

Ευχαριστίες

Σε αυτό το σημείο θα ήθελα να εκφράσω τις ειλικρινείς μου ευχαριστίες προς τα άτομα που συνέβαλαν στην ολοκλήρωση αυτής της πτυχιακής εργασίας.

Αρχικά, θα ήθελα να ευχαριστήσω θερμά τον επιβλέποντα καθηγητή μου, κ. Νίκο Λάσκαρη, για την εμπιστοσύνη του και τη σημαντική συνεισφορά του στην τελική μορφή αυτής της εργασίας. Επίσης, θέλω να ευχαριστήσω τους γονείς μου και τους φίλους μου για την αμέριστη υποστήριξή τους κατά τη διάρκεια των προπτυχιακών μου σπουδών. Η συμβολή και η στήριξή σας ήταν κρίσιμη για την επίτευξη αυτού του σημαντικού σταδίου της εκπαίδευσής μου.

Περιεχόμενα

Κεφάλαιο 1.....	8
Εισαγωγή.....	8
1.1 Το πρόβλημα.....	8
1.2 Στόχος Πτυχιακής.....	9
1.3 Διάρθρωση Κειμένου.....	11
Κεφάλαιο 2.....	13
Θεωρητικό Υπόβαθρο.....	13
2.1 Εισαγωγή στο EEG.....	13
2.2 Ανάλυση Σημάτων EEG.....	16
2.2.1 Χαρακτηριστικά Σημάτων EEG στο Πεδίο του Χρόνου και της Συχνότητας.....	16
2.3 Θεωρητικά θεμέλια της Αρχιτεκτονικής CNN.....	20
2.3.1 Συνελικτικά Στρώματα.....	20
2.3.2 Στρώματα Συγκέντρωσης.....	23
2.3.3 Κανονικοποίηση συνόλων.....	24
2.3.4 Ρυθμισμένες Γραμμικές Μονάδες.....	26
2.3.5 Πλήρως Συνδεδεμένα Στρώματα.....	28
2.3.6 Στρώμα Εισόδου Ακολουθίας.....	30
2.3.7 Χρήση Βαρών στις Κλάσεις (Class Weights):.....	32
2.4 Εφαρμογές των Νευρωνικών Δικτύων στην Ανάλυση Σημάτων EEG.....	33
Κεφάλαιο 3.....	39
Υλοποίηση Συστήματος.....	39
3.1 Εισαγωγή.....	39
3.2 Προετοιμασία και Φόρτωση Δεδομένων.....	39
3.2.1 Κατέβασμα και Αποσυμπίεση Δεδομένων.....	39
3.2.2 Οργάνωση και Κατηγοριοποίηση Δεδομένων.....	40
3.3 Κατασκευή του Νευρωνικού Δικτύου.....	42
3.3.1 Αρχιτεκτονική Νευρωνικού Δικτύου για Ταξινόμηση Σημάτων EEG.....	42
3.3.2 Εκπαίδευση του Νευρωνικού Δικτύου Επεξεργασίας Σημάτων EEG (SPN).....	47
3.4 Εργαλεία και Τεχνολογίες Υλοποίησης.....	49
Κεφάλαιο 4.....	51
Αξιολόγηση του Συστήματος και Παρουσίαση Αποτελεσμάτων.....	51
4.1 Εισαγωγή.....	51
4.2 Αποτελέσματα Εκπαίδευσης και Επικύρωσης.....	53
4.3 Περαιτέρω Ανάλυση.....	59
Κεφάλαιο 5.....	62

Επίλογος.....	62
5.1 Συμπεράσματα και Επιλογή Μοντέλου.....	62
5.2 Περιορισμοί της Μελέτης.....	64
5.3 Μελλοντικές Κατευθύνσεις.....	64
Βιβλιογραφία.....	66

Κατάλογος Σχημάτων

Σχήμα 1: Κανονικό σήμα EEG.....	13
Σχήμα 2: Σήμα EEG με Επιληπτικές Αιχμές.....	14
Σχήμα 3: Κατανομή Συχνοτήτων του Σήματος EEG.....	15
Σχήμα 4: Scalogram.....	47
Σχήμα 5: Εκπαίδευση Δικτύου.....	54

Κατάλογος Πινάκων

Πίνακας 1: Πίνακας Δειγμάτων.....	52
Πίνακας 2: Πίνακας Σύγχυσης.....	56
Πίνακας 4: Πίνακας recall.....	57
Πίνακας 5: Πίνακας F1.....	58
Πίνακας 6: Πίνακας Διαμορφώσεων και Αποτελεσμάτων.....	59
Πίνακας 7: Πρώτο Μοντέλο - Πίνακας 8: Δεύτερο Μοντέλο.....	60
Πίνακας 9: Τρίτο Μοντέλο - Πίνακας 10: Τέταρτο Μοντέλο.....	60
Πίνακας 11: Πέμπτο Μοντέλο Πίνακας 12: Έκτο Μοντέλο.....	61
Πίνακας 13: Έβδομο Μοντέλο Πίνακας 14: Όγδοο Μοντέλο.....	61

Συντομογραφίες & Ακρωνύμια

CNN	Convolutional Neural Network
EEG	Electroencephalogram
ΗΕΓ	Ηλεκτροεγκεφαλογράφημα
ΦΠΙ	Φασματική πυκνότητα ισχύος
ReLU	Ρυθμισμένες Γραμμικές Μονάδες
BCI	Brain-Computer Interfaces
TRM	Topographic Representation Module
CWT	Continuous Wavelet Transform
SPN	Signal Processing Network
GAN	Generative Adversarial Networks
RNN	Recurrent Neural Networks
LSTM	Long Short-Term Memory
EMG	Electromyography

Κεφάλαιο 1

Εισαγωγή

1.1 Το πρόβλημα

Η επιληψία, μια νευρολογική διαταραχή που επηρεάζει εκατομμύρια ανθρώπους παγκοσμίως, αποτελεί μια από τις πιο κοινές αλλά και περίπλοκες νευρολογικές καταστάσεις. Σύμφωνα με στατιστικά στοιχεία, πάνω από 1,2 εκατομμύρια άνθρωποι αντιμετωπίζουν επιληψία, με πολλούς από αυτούς να υποφέρουν από συχνές και απρόβλεπτες κρίσεις παρά τη χρήση αντιεπιληπτικών φαρμάκων [1][3]. Οι επιληπτικές κρίσεις μπορούν να έχουν πολλαπλές αιτίες, συμπεριλαμβανομένων εγκεφαλικών βλαβών, κρανιοκεφαλικών τραυμάτων, χρωμοσωμικών και αναπτυξιακών διαταραχών, κληρονομικών ασθενειών, καθώς και γενετικών ή άγνωστων παραγόντων [23][4].

Η διαχείριση της επιληψίας παρουσιάζει σημαντικές προκλήσεις λόγω της ποικιλίας των αιτιών και των μορφών κρίσεων. Η ακριβής διάγνωση και η αποτελεσματική παρακολούθηση της κατάστασης απαιτούν την ανάλυση των επιληπτικών εκφορτίσεων, οι οποίες παρέχουν πολύτιμες πληροφορίες σχετικά με τη φύση των κρίσεων και τον τύπο της επιληψίας. Το ΗΕΓ είναι ένα βασικό εργαλείο στη διαγνωστική διαδικασία για την επιληψία, καθώς αποτελεί μια από τις πιο συνηθισμένες κλινικές μεθόδους για την αξιολόγηση της νευρικής δραστηριότητας.

Η εξέταση ΗΕΓ είναι κρίσιμη για την απάντηση τριών βασικών ερωτημάτων στη διαγνωστική διαδικασία των ασθενών με επιληψία [2]:

1. **Έχει ο ασθενής επιληψία;** Το ΗΕΓ βοηθά στην ανίχνευση ανώμαλων νευρικών δραστηριοτήτων που μπορεί να υποδεικνύουν την παρουσία επιληψίας.
2. **Πού βρίσκεται η επιληπτική ζώνη;** Ο εντοπισμός της επιληπτικής ζώνης είναι ζωτικής σημασίας για τον προσδιορισμό των περιοχών του εγκεφάλου που εμπλέκονται στις κρίσεις.

3. Πόσο αποτελεσματική είναι η θεραπεία; Το ΗΕΓ χρησιμοποιείται για την αξιολόγηση της αποτελεσματικότητας των αντιεπιληπτικών φαρμάκων και άλλων θεραπευτικών παρεμβάσεων.

Η διαδικασία αυτή είναι ιδιαίτερα προκλητική καθώς τα κλινικά χρησιμοποιούμενα ηλεκτροεγκεφαλογράφημα που τοποθετούνται στο τριχωτό της κεφαλής συχνά περιέχουν υψηλά επίπεδα θορύβου και παρεμβολών. Αυτό το θορυβώδες περιβάλλον καθιστά δύσκολη την ανίχνευση και την ανάλυση των κρίσιμων χαρακτηριστικών των σημάτων ΗΕΓ. Για την αντιμετώπιση αυτής της πρόκλησης, υπάρχει αυξανόμενη ανάγκη για την ανάπτυξη προηγμένων αλγορίθμων και τεχνικών που μπορούν να επιτρέψουν την αυτόματη ανίχνευση των επιληπτικών εκφορτίσεων ή άλλων σημαντικών χαρακτηριστικών από τα δεδομένα ΗΕΓ.

Οι σύγχρονες τεχνικές ανάλυσης δεδομένων, όπως η μηχανική μάθηση και ειδικότερα τα συνελκτικά νευρωνικά δίκτυα, προσφέρουν νέες δυνατότητες για την επεξεργασία και την ανάλυση των σημάτων ΗΕΓ. Αυτές οι τεχνικές επιτρέπουν την εξαγωγή πολύπλοκων χαρακτηριστικών και την αναγνώριση προτύπων που δεν είναι εύκολα αντιληπτά με τις παραδοσιακές μεθόδους. Μέσω της χρήσης αυτών των προηγμένων μεθόδων, μπορούμε να επιτύχουμε μεγαλύτερη ακρίβεια στην ανίχνευση και την κατηγοριοποίηση των επιληπτικών κρίσεων, βελτιώνοντας έτσι την ποιότητα ζωής των ασθενών με επιληψία.

1.2 Στόχος Πτυχιακής

Στο πλαίσιο αυτής της πτυχιακής εργασίας, ο στόχος είναι να χρησιμοποιήσουμε την Μηχανική Μάθηση για την ανίχνευση της επιληψίας στο ηλεκτροεγκεφαλογράφημα, χρησιμοποιώντας ένα Νευρωνικό Δίκτυο Συνέλιξης. Το CNN αυτό θα είναι σε θέση να ανιχνεύει γρήγορα την έναρξη των επιληπτικών κρίσεων μέσω της ανάλυσης της ηλεκτρικής δραστηριότητας του εγκεφάλου. Ο κύριος στόχος αυτής της εργασίας είναι να ελαχιστοποιηθεί τόσο ο χρόνος καθυστέρησης στην ανίχνευση των επιληπτικών επεισοδίων όσο και ο αριθμός των ψευδών ανιχνεύσεων από τον αλγόριθμο. Ταυτόχρονα, στοχεύουμε στη διατήρηση υψηλού επιπέδου ακρίβειας στην ανίχνευση.

Η ανίχνευση των επιληπτικών κρίσεων με μεγαλύτερη ταχύτητα και ακρίβεια μπορεί να έχει σημαντική επίδραση στη βελτίωση της ποιότητας ζωής των ατόμων που πάσχουν από επιληψία. Οι ασθενείς θα μπορούν να λαμβάνουν άμεσες ειδοποιήσεις και βοήθεια κατά τη διάρκεια μιας κρίσης, ενώ οι γιατροί θα μπορούν να παρακολουθούν την κατάσταση των ασθενών τους σε πραγματικό χρόνο και να προσαρμόζουν τις θεραπευτικές τους στρατηγικές ανάλογα.

Επιπλέον, η μελέτη αυτή αποσκοπεί στη χρήση ενός μεγάλου συνόλου δεδομένων ΗΕΓ που συμπεριλαμβάνει καταγραφές από εθελοντές υπό διαφορετικές συνθήκες (με ανοικτά και κλειστά μάτια) και καταγραφές από ασθενείς με επιληψία και χωρίς. Αυτά τα σύνολα δεδομένων, χαρακτηρισμένα αντίστοιχα ως Α, Β, Γ, Δ και Ε, παρέχουν πολύτιμες πληροφορίες για διάφορες καταστάσεις και δραστηριότητες του εγκεφάλου.

Συγκεκριμένα:

- **Κατηγορία Α:** Καταγραφές από φυσιολογικούς εθελοντές με ανοικτά μάτια.
- **Κατηγορία Β:** Καταγραφές από φυσιολογικούς εθελοντές με κλειστά μάτια.
- **Κατηγορία Γ:** Καταγραφές από ασθενείς με επιληψία κατά τη διάρκεια μιας επιληπτικής κρίσης.
- **Κατηγορία Δ:** Καταγραφές από ασθενείς με επιληψία μεταξύ των κρίσεων.
- **Κατηγορία Ε:** Καταγραφές από ασθενείς χωρίς επιληψία.

Χρησιμοποιώντας αυτό το σύνολο δεδομένων, στοχεύουμε στο να εκπαιδεύσουμε το CNN ώστε να διακρίνει αποτελεσματικά μεταξύ της φυσιολογικής δραστηριότητας του εγκεφάλου και των επιληπτικών επεισοδίων, βελτιώνοντας την ικανότητά του να ανιχνεύει επιληπτικές κρίσεις με ακρίβεια και αποτελεσματικότητα. Μέσω αυτής της εκπαίδευσης, το CNN θα μάθει να αναγνωρίζει τα μοναδικά μοτίβα και τις ανωμαλίες που συνδέονται με τις επιληπτικές κρίσεις, επιτρέποντας την ακριβή διάγνωση και την έγκαιρη παρέμβαση.

Τέλος, η έρευνα αυτή φιλοδοξεί να συμβάλει στην επιστημονική κοινότητα προσφέροντας νέες μεθόδους και αλγορίθμους που μπορούν να χρησιμοποιηθούν στην κλινική πρακτική για τη βελτίωση της διάγνωσης και της διαχείρισης της επιληψίας. Η ανάπτυξη ενός τέτοιου εργαλείου μπορεί να έχει ευρείες εφαρμογές, όχι μόνο για την επιληψία αλλά και για άλλες νευρολογικές διαταραχές που απαιτούν ακριβή και γρήγορη ανίχνευση.

1.3 Διάρθρωση Κειμένου

Στο πρώτο κεφάλαιο, έγινε μια εκτενής περιγραφή του προβλήματος και επισημάνθηκε η σημασία των προκλήσεων που αντιμετωπίζονται σε αυτήν την πτυχιακή εργασία. Παρουσιάστηκαν οι στόχοι της έρευνας και το γενικό πλαίσιο στο οποίο αυτή εντάσσεται. Στα επόμενα κεφάλαια, η δομή της πτυχιακής εργασίας διαμορφώνεται ως εξής:

Κεφάλαιο 2: Θεωρητικό Υπόβαθρο

Σε αυτό το κεφάλαιο, περιγράφονται βασικές θεωρητικές έννοιες που συμβάλλουν στην κατανόηση του αντικειμένου της πτυχιακής και του τρόπου υλοποίησης. Αναλύονται οι αρχές της μηχανικής μάθησης και ειδικότερα τα συνελκτικά νευρωνικά δίκτυα, τα οποία αποτελούν τον πυρήνα της προτεινόμενης μεθοδολογίας. Επιπλέον, εξετάζονται οι βασικές τεχνικές επεξεργασίας και ανάλυσης σημάτων EEG, καθώς και οι προκλήσεις που σχετίζονται με την ανίχνευση επιληπτικών κρίσεων. Το θεωρητικό υπόβαθρο είναι κρίσιμο για την κατανόηση των τεχνικών και των εργαλείων που χρησιμοποιούνται στην υλοποίηση του συστήματος.

Κεφάλαιο 3: Υλοποίηση του Συστήματος

Αυτό το κεφάλαιο περιλαμβάνει μια αναλυτική περιγραφή της υλοποίησης του συστήματος ταξινόμησης σημάτων EEG. Ξεκινάμε με την προεπεξεργασία των δεδομένων EEG, περιγράφοντας τα βήματα καθαρισμού και κανονικοποίησης των δεδομένων. Στη συνέχεια, αναλύουμε την ανάπτυξη και την εκπαίδευση του τελικού συνελκτικού νευρωνικού δικτύου (CNN) που επιλέξαμε για το έργο μας. Εξετάζουμε τις παραμέτρους του δικτύου, όπως τον αριθμό και το μέγεθος των συνελκτικών φίλτρων, τα επίπεδα pooling και τις πλήρως συνδεδεμένες στρώσεις. Αναφέρουμε τις τεχνικές βελτιστοποίησης που χρησιμοποιήθηκαν, όπως η χρήση της Adam optimizer και η κανονικοποίηση batch, καθώς

και τις μεθόδους αξιολόγησης της απόδοσης του μοντέλου. Επιπλέον, παρουσιάζονται λεπτομερώς οι αλγόριθμοι που χρησιμοποιούνται και οι διαδικασίες για την αυτόματη ανίχνευση των επιληπτικών εκφορτίσεων.

Κεφάλαιο 4: Αξιολόγηση και Αποτελέσματα

Σε αυτό το κεφάλαιο, γίνεται αξιολόγηση του τελικού μοντέλου και παρουσίαση των αποτελεσμάτων των υπολοίπων επτά μοντέλων που εξετάστηκαν κατά τη διάρκεια της έρευνας. Η απόδοση του τελικού μοντέλου αξιολογείται σε διάφορα σύνολα δεδομένων, και τα αποτελέσματα αναλύονται με βάση μετρικές όπως η ακρίβεια και η βαθμολογία F1. Κάθε ένα από τα επτά επιπλέον μοντέλα που εξετάστηκαν παρουσιάζεται λεπτομερώς, με συγκριτική ανάλυση της απόδοσής τους. Αναλύονται τα πιθανά λάθη και οι περιορισμοί κάθε μοντέλου, καθώς και οι λόγοι για τους οποίους το τελικό μοντέλο επιλέχθηκε ως το βέλτιστο.

Κεφάλαιο 5: Επίλογος

Το τελικό κεφάλαιο συνοψίζει τα κύρια ευρήματα της πτυχιακής εργασίας και καταλήγει σε συμπεράσματα σχετικά με την αποτελεσματικότητα της προτεινόμενης μεθοδολογίας. Αναλύονται οι λόγοι για τους οποίους επιλέχθηκε το τελικό μοντέλο μεταξύ των άλλων επτά που εξετάστηκαν, εστιάζοντας στη συνολική απόδοση και στην ικανότητα γενίκευσης. Συζητούνται οι επιπτώσεις των αποτελεσμάτων στην κλινική πρακτική και στην επιστημονική κοινότητα, καθώς και οι δυνατότητες για μελλοντική ανάπτυξη και εφαρμογή των τεχνικών που παρουσιάστηκαν. Ο επίλογος παρέχει επίσης μια ανασκόπηση των στόχων που επιτεύχθηκαν και των περιοχών που χρήζουν περαιτέρω διερεύνησης.


Κεφάλαιο 2

Θεωρητικό Υπόβαθρο

2.1 Εισαγωγή στο EEG

Το ηλεκτροεγκεφαλογράφημα αποτελεί μια διερεύνηση της νευρωνικής δυναμικής, προσφέροντας ένα παράθυρο στις περίπλοκες λειτουργίες του ανθρώπινου εγκεφάλου. Τα σήματα EEG περικλείουν έναν πλούτο πληροφοριών ζωτικής σημασίας για την κατανόηση της γνώσης, της συμπεριφοράς και των νευρολογικών διαταραχών. Έγκειται στην ικανότητά του να καταγράφει τη χρονική δυναμική της νευρικής δραστηριότητας με μεγάλη ακρίβεια αξιοποιώντας συστοιχίες ηλεκτροδίων στο τριχωτό της κεφαλής, επιτρέποντας τη μη επεμβατική παρακολούθηση των νευρωνικών ταλαντώσεων σε διάφορες ζώνες συχνοτήτων. Ωστόσο, το ταξίδι από τα ακατέργαστα δεδομένα EEG σε ουσιαστικές γνώσεις είναι γεμάτο προκλήσεις.


Στο Γράφημα 1, παρουσιάζεται ένα κανονικό σήμα EEG, το οποίο δείχνει την τυπική δραστηριότητα του εγκεφάλου με κύματα alpha και προσθήκη θορύβου. Αυτό το παράδειγμα απεικονίζει την βασική λειτουργία ενός υγιούς εγκεφάλου χωρίς ανωμαλίες.



Σχήμα 1: Κανονικό σήμα EEG

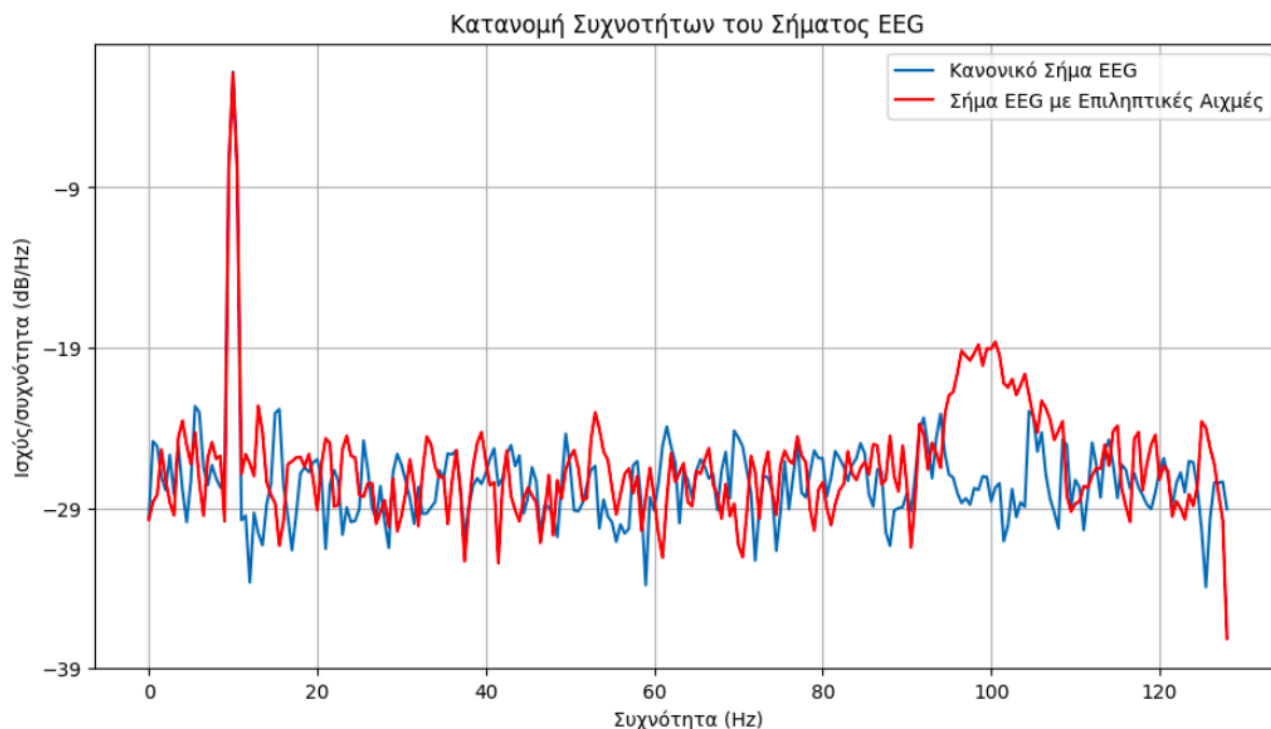
Οι παραδοσιακές τεχνικές ανάλυσης EEG, αν και ισχυρές, συχνά δυσκολεύονται να ξετυλίξουν τον πολύπλοκο ιστό της νευρικής δραστηριότητας που ενσωματώνεται στις καταγραφές EEG. Παραδοσιακές μέθοδοι, όπως οι μέθοδοι ανάλυσης χρόνου-συχνότητας και οι φασματικές αναλύσεις, παρέχουν πολύτιμη πληροφορία, αλλά μπορεί να μην είναι

επαρκείς για την πλήρη αποκωδικοποίηση των πολύπλοκων μοτίβων που σχετίζονται με νευρολογικές διαταραχές, όπως η επιληψία. Χρειάζονται προχωρημένες μεθοδολογίες που μπορούν να επεξεργαστούν τα μεγάλα και πολύπλοκα σύνολα δεδομένων EEG με υψηλή ευαισθησία και εξειδίκευση. Στο Γράφημα 2, παρουσιάζεται ένα σήμα EEG με επιληπτικές αιχμές. Αυτές οι αιχμές είναι έντονες και διακριτές από το κανονικό κύμα, υποδεικνύοντας την παρουσία επιληπτικής δραστηριότητας. Η αναγνώριση αυτών των αιχμών είναι κρίσιμη για τη διάγνωση και την παρακολούθηση επιληπτικών επεισοδίων.



Σχήμα 2: Σήμα EEG με Επιληπτικές Αιχμές

Στο Γράφημα 3, παρουσιάζεται η κατανομή συχνοτήτων του κανονικού σήματος EEG και του σήματος με επιληπτικές αιχμές. Αυτό το διάγραμμα δείχνει την φασματική πυκνότητα ισχύος (PSD) για τα δύο σήματα, αποκαλύπτοντας διαφορές στην ισχύ σε διάφορες συχνότητες που είναι χαρακτηριστικές για την επιληπτική δραστηριότητα.



Σχήμα 3: Κατανομή Συχνοτήτων του Σήματος EEG

Εδώ είναι που οι μεθοδολογίες της μηχανικής μάθησης, όπως τα νευρωνικά συνελκτικά δίκτυα ανάλυσης, αναδεικνύονται. Τα τελευταία χρόνια, τα CNN έχουν φέρει επανάσταση στον τομέα της μηχανικής μάθησης, επιδεικνύοντας αξιοσημείωτη ικανότητα στην εξαγωγή περίπλοκων μοτίβων από πολύπλοκες μορφές δεδομένων. Αξιοποιώντας την ιεραρχική αρχιτεκτονική τους και τις δυνατότητες εξαγωγής ιεραρχικών χαρακτηριστικών, τα CNN προσφέρουν μια υποσχόμενη οδό για την αποκωδικοποίηση των πλούσιων σημάτων EEG. Εκπαιδεύοντας μοντέλα CNN σε σύνολα δεδομένων, γίνεται προσπάθεια αποκάλυψης για τις υποκείμενες νευρωνικές υπογραφές που σχετίζονται με τα γνωστικά φαινόμενα.

Η ενσωμάτωση των CNN στην ανάλυση EEG προσφέρει τη δυνατότητα αυτόματης ανίχνευσης και ταξινόμησης διαφόρων τύπων νευρωνικής δραστηριότητας, με ακρίβεια που ξεπερνά τις παραδοσιακές μεθόδους. Η εφαρμογή τους έχει αποδειχθεί αποτελεσματική στην ανίχνευση επιληπτικών κρίσεων, την πρόβλεψη επιληπτικών επεισοδίων και τη διάγνωση άλλων νευρολογικών καταστάσεων. Μέσω σχολαστικού πειραματισμού, η έρευνα επιδιώκει να διευρύνει τα όρια της ανάλυσης του EEG, ανοίγοντας νέες προοπτικές για την κατανόηση της λειτουργίας και της παθολογίας του εγκεφάλου.

Στα κεφάλαια που ακολουθούν, εμβαθύνουμε στις ιδιαιτερότητες της επεξεργασίας δεδομένων EEG, του σχεδιασμού της αρχιτεκτονικής CNN και των μεθοδολογιών επικύρωσης μοντέλων συνδυάζοντας γνώσεις από τη νευροεπιστήμη και τη μηχανική μάθηση.

2.2 Ανάλυση Σημάτων EEG

Η ανάλυση σημάτων EEG με τη χρήση βαθιών νευρωνικών δικτύων αποτελεί μια από τις πλέον σύγχρονες και αποτελεσματικές μεθόδους στην κατανόηση της εγκεφαλικής δραστηριότητας. Τα βαθιά νευρωνικά δίκτυα, και ιδιαίτερα τα συνελκτικά νευρωνικά δίκτυα, έχουν αποδείξει την ικανότητά τους να εξάγουν περίπλοκα χαρακτηριστικά από τα δεδομένα, που είναι απαραίτητα για την ακριβή ανάλυση και ταξινόμηση των σημάτων EEG.

Τα χαρακτηριστικά των σημάτων EEG διακρίνονται σε τρεις βασικές κατηγορίες [7] :

- α) Απλά στατιστικά χαρακτηριστικά στο πεδίο του χρόνου (time-domain features)
- β) Χαρακτηριστικά στο πεδίο της συχνότητας (frequency-domain features)
- γ) Άλλα μη γραμμικά χαρακτηριστικά

Κάθε κατηγορία προσφέρει μοναδικές πληροφορίες για τη νευρωνική δραστηριότητα και είναι κρίσιμη για την πλήρη κατανόηση του EEG. Ο κύριος στόχος της παρούσας μελέτης είναι να εμβαθύνουμε σε αυτά τα χαρακτηριστικά, προκειμένου να κατανοήσουμε περαιτέρω τη λειτουργία του EEG και να αναπτύξουμε βελτιστοποιημένα μοντέλα βαθιάς μάθησης που μπορούν να χρησιμοποιηθούν για την ακριβή διάγνωση και πρόβλεψη νευρολογικών καταστάσεων.

2.2.1 Χαρακτηριστικά Σημάτων EEG στο Πεδίο του Χρόνου και της Συχνότητας

Τα σήματα ηλεκτροεγκεφαλογραφίας παρουσιάζουν πολύπλοκα χρονικά και φασματικά χαρακτηριστικά που μεταφέρουν πολύτιμες πληροφορίες σχετικά με την εγκεφαλική δραστηριότητα. Η ανάλυση των σημάτων EEG περιλαμβάνει συχνά την εξαγωγή χαρακτηριστικών τόσο από τον τομέα του χρόνου όσο και από τον τομέα συχνότητας για την καταγραφή διαφορετικών πτυχών της νευρωνικής δυναμικής. Σε αυτή την ενότητα, εμβαθύνουμε στα βασικά χαρακτηριστικά που εξάγονται από τα σήματα EEG στους τομείς του χρόνου και της συχνότητας, διευκρινίζοντας τη σημασία τους για την

κατανόηση της λειτουργίας και της παθολογίας του εγκεφάλου. Τα χαρακτηριστικά στον τομέα του χρόνου ενσωματώνουν τη χρονική δυναμική των σημάτων EEG και παρέχουν πληροφορίες για τη χρονική εξέλιξη της νευρικής δραστηριότητας.

Χαρακτηριστικά στον τομέα του χρόνου περιλαμβάνουν:

- Πλάτος: Το μέγεθος των διακυμάνσεων του σήματος EEG, που αντικατοπτρίζει την ισχύ του νευρωνικού συγχρονισμού και αποσυγχρονισμού [8]. Μετρώντας το πλάτος, μπορούμε να εκτιμήσουμε την ένταση της νευρικής δραστηριότητας και να εντοπίσουμε ανωμαλίες που ενδέχεται να σχετίζονται με νευρολογικές διαταραχές.
- Διάρκεια: Η χρονική διάρκεια συγκεκριμένων μοτίβων ή συμβάντων EEG, όπως αιχμές, εκρήξεις (bursts - ξαφνικές και γρήγορες αυξήσεις της δραστηριότητας) και επιληπτικές κρίσεις [10]. Αυτή η μέτρηση βοηθά στην κατανόηση της χρονικής πορείας των νευρικών γεγονότων και μπορεί να αποκαλύψει την παρουσία παρατεταμένων ή σύντομων επεισοδίων ανώμαλης δραστηριότητας.
- Κλίση: Ο ρυθμός μεταβολής του πλάτους του σήματος EEG με την πάροδο του χρόνου, αποκαλύπτοντας απότομες μεταβάσεις ή σταδιακές τάσεις στη νευρική δραστηριότητα [11]. Η ανάλυση της κλίσης μπορεί να βοηθήσει στην ανίχνευση απότομων αλλαγών στην εγκεφαλική δραστηριότητα, που συχνά υποδηλώνουν κρίσιμες νευρολογικές καταστάσεις.
- Διακοπές: Η εμφάνιση διακοπτόμενων ή παροδικών δραστηριοτήτων, που χαρακτηρίζονται από εναλλασσόμενες περιόδους σε υψηλά και χαμηλά πλάτη EEG. Αυτά τα χαρακτηριστικά μπορούν να υποδηλώνουν την παρουσία περιόδων αυξημένης ή μειωμένης νευρικής δραστηριότητας, οι οποίες είναι σημαντικές για τη διάγνωση διαταραχών όπως η επιληψία.

•

Χαρακτηριστικά στον Τομέα της Συχνότητας:

Η ανάλυση στον τομέα της συχνότητας αποσυνθέτει τα σήματα EEG στα στοιχεία συχνότητας, επιτρέποντας τον χαρακτηρισμό φασματικών μοτίβων και φαινομένων ταλάντωσης. Αυτή η προσέγγιση παρέχει μια βαθύτερη κατανόηση των συχνοτήτων που

κυριαρχούν στα σήματα EEG και της σχετικής ισχύος τους, βοηθώντας στη διάγνωση και την κατανόηση νευρολογικών καταστάσεων.

1. Φασματική πυκνότητα ισχύος: Η φασματική πυκνότητα ισχύος είναι ένα από τα πιο θεμελιώδη και σημαντικά χαρακτηριστικά στην ανάλυση των σημάτων EEG. Αφορά την κατανομή της ισχύος του σήματος σε διαφορετικές ζώνες συχνοτήτων. Αυτές οι ζώνες περιλαμβάνουν:
 - a. **Δέλτα (0,5-4 Hz):** Τα κύματα δέλτα συνήθως σχετίζονται με βαθύ ύπνο και φάσεις αποκατάστασης του οργανισμού. Είναι ενδεικτικά χαμηλής εγρήγορσης και χαμηλής νευρικής δραστηριότητας.
 - b. **Θήτα (4-8 Hz):** Τα κύματα θήτα συχνά συνδέονται με κατάσταση ηρεμίας, δημιουργικής σκέψης και ελαφρού ύπνου. Αυτά τα κύματα μπορούν να παρατηρηθούν κατά τη διάρκεια της μετάβασης από την εγρήγορση στον ύπνο.
 - c. **Άλφα (8-12 Hz):** Τα κύματα άλφα εμφανίζονται συχνά κατά τη διάρκεια χαλάρωσης με κλειστά μάτια και είναι ενδεικτικά καταστάσεων ηρεμίας και χαλάρωσης. Επίσης, μπορούν να συνδεθούν με εγκεφαλικές καταστάσεις διαλογισμού.
 - d. **Βήτα (12-30 Hz):** Τα κύματα βήτα σχετίζονται με ενεργή σκέψη, συγκέντρωση και εγρήγορση. Υψηλή παρουσία βήτα κυμάτων μπορεί να υποδηλώνει έντονη νοητική δραστηριότητα και άγχος.
 - e. **Γάμμα (>30 Hz):** Τα κύματα γάμμα συνδέονται με ανώτερες νοητικές λειτουργίες, όπως η επεξεργασία πληροφοριών, η μνήμη και η συνείδηση. Είναι ενδεικτικά υψηλής γνωστικής λειτουργίας και σύνθετων εγκεφαλικών διεργασιών.

Η ανάλυση της ΦΠΙ μας επιτρέπει να κατανοήσουμε ποια είναι η κυρίαρχη συχνότητα στα σήματα EEG, δίνοντάς μας πληροφορίες για την κατάσταση του εγκεφάλου [11].

2. Αναλογίες ζώνης συχνότητας : Οι αναλογίες ζώνης συχνότητας αναφέρονται στις αναλογίες ισχύος ή πλάτους μεταξύ διαφορετικών ζωνών συχνοτήτων. Αυτές οι αναλογίες είναι ιδιαίτερα χρήσιμες για την αξιολόγηση της δυναμικής των νευρωνικών δικτύων και των γνωστικών καταστάσεων του ατόμου.

Για παράδειγμα:

- a. **Αναλογία Θήτα προς Άλφα:** Μια αυξημένη αναλογία θήτα προς άλφα μπορεί να υποδηλώνει κατάσταση αυξημένης γνωστικής προσπάθειας ή στρες. Αυτό μπορεί να παρατηρηθεί σε άτομα που βρίσκονται σε κατάσταση εγρήγορσης και προβληματισμού.
- b. **Αναλογία Άλφα προς Βήτα:** Μια υψηλή αναλογία άλφα προς βήτα μπορεί να είναι ενδεικτική κατάστασης ηρεμίας και χαλάρωσης. Αυτή η αναλογία χρησιμοποιείται συχνά για την αξιολόγηση της ψυχολογικής κατάστασης του ατόμου και την παρακολούθηση της ψυχικής υγείας.

Αυτές οι αναλογίες μπορούν να χρησιμοποιηθούν για την παρακολούθηση αλλαγών στην εγκεφαλική δραστηριότητα και την κατανόηση των υποκείμενων νευρωνικών μηχανισμών [12].

3. Η φασματική εντροπία μετρά την πολυπλοκότητα ή ανωμαλία του φάσματος των σημάτων EEG, αξιολογώντας τη φασματική μεταβλητότητα και το περιεχόμενο πληροφοριών. Υψηλή εντροπία υποδηλώνει μεγαλύτερη πολυπλοκότητα, ενώ χαμηλή εντροπία δείχνει πιο προβλέψιμη εγκεφαλική δραστηριότητα. Αυτή η ανάλυση είναι σημαντική για την κατανόηση της κατάστασης του εγκεφάλου, αποκαλύπτοντας αλλαγές που σχετίζονται με παθολογικές καταστάσεις ή διαφορετικές καταστάσεις συνείδησης. Για παράδειγμα, αυξήσεις στη φασματική εντροπία μπορεί να παρατηρηθούν σε επιληπτικές κρίσεις, ενώ μειώσεις μπορεί να σχετίζονται με το κώμα ή την αναισθησία. Η φασματική εντροπία μπορεί επίσης να διακρίνει διαφορετικές γνωστικές καταστάσεις, προσφέροντας σημαντικές πληροφορίες για τη λειτουργία και την υγεία του εγκεφάλου και χρησιμοποιείται για την παρακολούθηση της αποτελεσματικότητας των θεραπειών και την αξιολόγηση της εγκεφαλικής απόκρισης σε διάφορα ερεθίσματα.

2.3 Θεωρητικά θεμέλια της Αρχιτεκτονικής CNN

2.3.1 Συνελικτικά Στρώματα

Τα συνελικτικά στρώματα (Convolutional Layers) [22] αποτελούν ένα πολύ σημαντικό παράγοντα των συνελικτικών νευρωνικών δικτύων, διαδραματίζοντας καθοριστικό ρόλο στην εκμάθηση ιεραρχικών αναπαραστάσεων των δεδομένων εισόδου. Αυτά τα στρώματα αξιοποιούν την έννοια της συνέλιξης για την εξαγωγή μοτίβων και χαρακτηριστικών από την είσοδο, διευκολύνοντας την αποτελεσματική εκμάθηση και αναπαράσταση χαρακτηριστικών.

Συγκεκριμένα, η συνέλιξη είναι μια μαθηματική πράξη που συνδυάζει δύο συναρτήσεις για να παράγει μια τρίτη. Στο πλαίσιο των συνελικτικών νευρωνικών δικτύων, τα συνελικτικά στρώματα χρησιμοποιούν φίλτρα ή πυρήνες για την εφαρμογή της συνέλιξης στα δεδομένα εισόδου. Κάθε φίλτρο είναι υπεύθυνο για την ανίχνευση συγκεκριμένων χαρακτηριστικών ή μοτίβων στα δεδομένα. Καθώς το φίλτρο μετακινείται (ή "συνελίσσεται") πάνω από τα δεδομένα εισόδου, υπολογίζει το γινόμενο μεταξύ των τιμών του φίλτρου και των τιμών των δεδομένων εισόδου σε κάθε θέση, παράγοντας έτσι έναν χάρτη χαρακτηριστικών.

Οι χάρτες χαρακτηριστικών που προκύπτουν από αυτή τη διαδικασία διατηρούν τις χωρικές σχέσεις των δεδομένων, επιτρέποντας την ανίχνευση τοπικών μοτίβων όπως άκρες και γωνίες. Καθώς βαδίζουμε στα βαθύτερα στρώματα του δικτύου, τα χαρακτηριστικά που εξάγονται γίνονται όλο και πιο αφηρημένα και σύνθετα, αντιπροσωπεύοντας τα δεδομένα εισόδου.

Τα συνελικτικά στρώματα διαφέρουν από τα πλήρως συνδεδεμένα στρώματα, καθώς κάθε νευρώνας σε ένα συνελικτικό στρώμα συνδέεται μόνο με μια μικρή περιοχή του προηγούμενου στρώματος, γνωστή ως τοπικό πεδίο υποδοχής. Αυτό μειώνει τον αριθμό των παραμέτρων και των υπολογιστικών πόρων που απαιτούνται, καθιστώντας τα συνελικτικά δίκτυα πιο αποδοτικά και κλιμακωτά.

Η χρήση των συνελικτικών στρωμάτων στα CNN έχει αποδειχθεί εξαιρετικά επιτυχημένη σε διάφορες εφαρμογές, όπως η αναγνώριση εικόνας, η ανάλυση σημάτων και η επεξεργασία φυσικής γλώσσας. Στην ανάλυση σημάτων EEG, τα συνελικτικά στρώματα

διευκολύνουν την ανίχνευση περίπλοκων μοτίβων που σχετίζονται με νευρολογικές καταστάσεις, προσφέροντας έτσι μια αξιόπιστη μέθοδο για την διάγνωση και παρακολούθηση της εγκεφαλικής δραστηριότητας.

1. Συνέλιξη

Η λειτουργία της συνέλιξης περιλαμβάνει την εφαρμογή εκπαιδευόμενων φίλτρων (γνωστών και ως πυρήνες) στα δεδομένα εισόδου. Κάθε φίλτρο μετακινείται με την είσοδο, υπολογίζοντας το γινόμενο μεταξύ των βαρών του φίλτρου και των τιμών εισόδου σε κάθε θέση. Αυτή η διαδικασία παράγει χαρακτηριστικά (χάρτες χαρακτηριστικών) που αναδεικνύουν τα μοτίβα που υπάρχουν στα δεδομένα εισόδου [19]. Συνέλιξη για διακριτές συναρτήσεις 2 σημάτων f και g :

$$(f * g)(x) = \sum_{k=-\infty}^{+\infty} f(k) \cdot g(x - k)$$

Συνέλιξη για συνεχείς συναρτήσεις 2 σημάτων f και g :

$$(f * g)(x) = \int_{-\infty}^{+\infty} f(k) \cdot g(x - k) dk$$

Μέσω της διαδικασίας της συνέλιξης, κάθε φίλτρο μαθαίνει να ανιχνεύει συγκεκριμένα τοπικά μοτίβα ή χαρακτηριστικά μέσα στην είσοδο. Καθώς το δίκτυο υποβάλλεται σε εκπαίδευση, τα φίλτρα προσαρμόζουν επαναληπτικά τα βάρη τους για να καταγράφουν σχετικά χαρακτηριστικά σε διαφορετικές τοποθεσίες. Αυτή η ιεραρχική διαδικασία εξαγωγής χαρακτηριστικών επιτρέπει στο δίκτυο να μαθαίνει όλο και πιο αφηρημένες και πολύπλοκες αναπαραστάσεις των δεδομένων εισόδου [13].

2. Τοπικά πεδία υποδοχής

Τα συνελκτικά στρώματα λειτουργούν με τοπικά πεδία (Local Receptive Fields), πράγμα που σημαίνει ότι κάθε νευρώνας μέσα σε έναν χάρτη χαρακτηριστικών συνδέεται με μια μικρή, εντοπισμένη περιοχή της εισόδου. Αυτή η τοπική συνδεσιμότητα είναι κρίσιμη για τη λειτουργία των συνελκτικών νευρωνικών δικτύων, καθώς επιτρέπει στο δίκτυο να

συλλαμβάνει αποτελεσματικά τις χωρικές εξαρτήσεις και τα μοτίβα στην είσοδο. Πιο συγκεκριμένα, το τοπικό δεκτικό πεδίο καθορίζει το τμήμα της εισόδου που θα "δει" κάθε νευρώνας. Για παράδειγμα, σε μια εικόνα, ένας νευρώνας μπορεί να συνδέεται μόνο με μια μικρή περιοχή, όπως 3x3 ή 5x5 pixels, αντί για ολόκληρη την εικόνα. Αυτή η περιορισμένη οπτική γωνία επιτρέπει στο δίκτυο να αναγνωρίζει βασικά χαρακτηριστικά όπως άκρες, γωνίες και υφές σε τοπικό επίπεδο. Καθώς προχωράμε σε βαθύτερα επίπεδα του δικτύου, αυτά τα τοπικά χαρακτηριστικά συνδυάζονται για να σχηματίσουν πιο σύνθετες αναπαραστάσεις[13].

3. Συμμετρία Μετατόπισης

Ένα βασικό πλεονέκτημα των συνελικτικών στρώματων είναι η ικανότητά τους να επιτυγχάνουν την αναλλοίωτη μετατόπιση (Translation Invariance). Αυτό σημαίνει ότι το δίκτυο μπορεί να αναγνωρίζει μοτίβα ανεξάρτητα από τη χωρική τους θέση στην είσοδο. Η αναλλοίωτη μετατόπιση είναι εξαιρετικά σημαντική για εφαρμογές όπως η αναγνώριση εικόνων, όπου η θέση των αντικειμένων μπορεί να μεταβάλλεται εντός της εικόνας. Πιο συγκεκριμένα, επιτρέπει στο δίκτυο να διατηρεί την ικανότητα αναγνώρισης ενός αντικειμένου ανεξάρτητα από το πού βρίσκεται στην εικόνα. Για παράδειγμα, ένα σύστημα αναγνώρισης εικόνων θα πρέπει να μπορεί να αναγνωρίζει μια γάτα είτε βρίσκεται στο κέντρο της εικόνας είτε στη γωνία. Αυτό επιτυγχάνεται μέσω της χρήσης φίλτρων που σαρώνουν ολόκληρη την εικόνα και ανιχνεύουν χαρακτηριστικά σε διάφορες θέσεις [13].

4. Ιεραρχική Αναπαράσταση

Τα συνελικτικά επίπεδα είναι συνήθως διατεταγμένα με ιεραρχικό τρόπο μέσα στις αρχιτεκτονικές των Συνελικτικών Νευρωνικών Δικτύων. Αυτό σημαίνει ότι τα στρώματα του δικτύου είναι οργανωμένα έτσι ώστε να καταγράφουν όλο και πιο αφηρημένα και υψηλού επιπέδου χαρακτηριστικά καθώς βαδίζουμε σε βαθύτερα επίπεδα. Η ιεραρχική αυτή δομή επιτρέπει στο δίκτυο να μαθαίνει και να αναπαριστά τα δεδομένα με έναν τρόπο που αντικατοπτρίζει την πολυπλοκότητα των χαρακτηριστικών. Στα χαμηλότερα στρώματα, τα φίλτρα τείνουν να ανιχνεύουν απλά χαρακτηριστικά, όπως ακμές, γωνίες και υφές. Αυτά τα βασικά χαρακτηριστικά είναι τα θεμέλια για την αναγνώριση πιο σύνθετων σχημάτων και

μοτίβων στα ανώτερα επίπεδα. Καθώς τα δεδομένα περνούν μέσα από τα διαδοχικά συνελικτικά επίπεδα, οι αναπαραστάσεις γίνονται πιο σύνθετες και αφαιρετικές.

5. Οπτικοποίηση χάρτη χαρακτηριστικών

Τεχνικές οπτικοποίησης, όπως η μεγιστοποίηση της ενεργοποίησης ή οι μέθοδοι που βασίζονται σε κλίση μπορούν να χρησιμοποιηθούν για την ερμηνεία των μαθησιακών χαρακτηριστικών εντός συνελικτικών επιπέδων. Αυτές οι τεχνικές παρέχουν πληροφορίες για τους τύπους προτύπων και χαρακτηριστικών που ανιχνεύει κάθε φίλτρο, βοηθώντας στην κατανόηση της συμπεριφοράς του δικτύου και της δυναμικής εκμάθησης χαρακτηριστικών [14].

6. Υπολογιστική Αποδοτικότητα

Τα συνελικτικά επίπεδα είναι υπολογιστικά αποδοτικά λόγω της κοινής χρήσης παραμέτρων και της αραιής συνδεσιμότητας, επιτρέποντας στα CNN να επεξεργάζονται μεγάλους όγκους δεδομένων με σχετικά λίγες παραμέτρους. Αυτή η αποτελεσματικότητα καθιστά τα CNN κατάλληλα για εργασίες που περιλαμβάνουν δεδομένα υψηλών διαστάσεων όπως εικόνες, βίντεο και σήματα χρονοσειρών [13].

2.3.2 Στρώματα Συγκέντρωσης

Τα στρώματα συγκέντρωσης (Pooling Layers)[14] [19] είναι βασικά συστατικά στα νευρωνικά δίκτυα συνελικτικής ανάλυσης, διαδραματίζοντας κρίσιμο ρόλο στη μείωση των χωρικών διαστάσεων και στον έλεγχο της υπερπροσαρμογής (overfitting). Τα στρώματα αυτά λειτουργούν σε χάρτες χαρακτηριστικών που παράγονται από τα συνελικτικά στρώματα, με στόχο τη σύνοψη της παρουσίας χαρακτηριστικών σε υποπεριοχές. Συνήθως χρησιμοποιούνται πράξεις pooling περιλαμβάνοντας τη μέγιστη συγκέντρωση (max pooling) και τη μέση συγκέντρωση (average pooling). Το max pooling επιλέγει τη μέγιστη τιμή από κάθε υποπεριοχή, ενώ το average pooling υπολογίζει το μέσο όρο.

Ειδικότερα, η μέγιστη συγκέντρωση διατηρεί τα πιο ενεργά χαρακτηριστικά σε κάθε υποπεριοχή, προάγοντας τη μεταφραστική αναλλοίωτη και ενισχύοντας την ανθεκτικότητα σε μικρές χωρικές μεταβολές των δεδομένων εισόδου. Αυτή η ιδιότητα καθιστά τη μέγιστη συγκέντρωση αποτελεσματική στη σύλληψη των κυρίαρχων χαρακτηριστικών, ενώ απορρίπτονται άσχετες λεπτομέρειες. Από την άλλη πλευρά, η μέση συγκέντρωση υπολογίζει τη μέση ενεργοποίηση σε κάθε υποπεριοχή, παρέχοντας μια πιο εξομαλυμένη αναπαράσταση των χαρακτηριστικών εισόδου.

Τα στρώματα συγκέντρωσης συμβάλλουν στη συνολική αρχιτεκτονική των CNN μειώνοντας την υπολογιστική πολυπλοκότητα και τον αριθμό των παραμέτρων, γεγονός που συμβάλλει στην αποφυγή της υπερπροσαρμογής και βελτιώνει την ικανότητα γενίκευσης του δικτύου. Επιπλέον, τα στρώματα συγκέντρωσης εισάγουν ένα βαθμό μεταφορικής αναλλοίωτης λειτουργίας, καθιστώντας τα CNN κατάλληλα για εργασίες όπως η ταξινόμηση εικόνων, όπου η χωρική διάταξη των χαρακτηριστικών μπορεί να ποικίλλει. Επιπλέον, τα στρώματα συγκέντρωσης ενισχύουν την αναλλοίωτη φύση των CNN σε μετατοπίσεις. Αυτό σημαίνει ότι αν ένα χαρακτηριστικό μετακινηθεί σε διαφορετική θέση στην είσοδο, το CNN θα μπορέσει να το αναγνωρίσει με την ίδια αποτελεσματικότητα, καθώς τα στρώματα συγκέντρωσης συνοψίζουν την πληροφορία σε κάθε υποπεριοχή, ανεξάρτητα από την ακριβή θέση των χαρακτηριστικών.

2.3.3 Κανονικοποίηση συνόλων

Η Κανονικοποίηση συνόλων (Batch normalization) είναι μια κρίσιμη τεχνική στην εκπαίδευση των νευρωνικών δικτύων, συμπεριλαμβανομένων των συνελικτικών. Η ομαδοποίηση συνόλων [20] αντιμετωπίζει το πρόβλημα της εσωτερικής μετατόπισης, κανονικοποιώντας τις εισόδους σε κάθε στρώμα. Αυτή η κανονικοποίηση διασφαλίζει ότι οι είσοδοι κάθε στρώματος έχουν μια συνεπή κατανομή, η οποία μπορεί να επιταχύνει σημαντικά την εκπαίδευση και να βελτιώσει τη σταθερότητα και την απόδοση του νευρωνικού δικτύου.

Η ομαλοποίηση συνόλων λειτουργεί κανονικοποιώντας την έξοδο του προηγούμενου στρώματος, αφαιρώντας τη μέση τιμή του συνόλου και διαιρώντας με την τυπική απόκλιση

της παρτίδας. Στη συνέχεια, κλιμακώνει και μετατοπίζει την κανονικοποιημένη έξοδο. Αυτή η διαδικασία μπορεί να εκφραστεί μαθηματικά ως εξής:

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$

$$y_i = \gamma \hat{x}_i + \beta$$

Όπου μ_B είναι ο μέσος όρος του συνόλου, σ_B^2 είναι η διακύμανση του συνόλου, ϵ είναι μια μικρή σταθερά για την αποφυγή της διαίρεσης με το μηδέν και γ και β είναι μαθησιακές παράμετροι που επιτρέπουν στο δίκτυο να κλιμακώνει και να μετατοπίζει την κανονικοποιημένη έξοδο.

Η εισαγωγή της κανονικοποιημένης παρτίδας έχει πολλά βασικά πλεονεκτήματα:

1. Επιτάχυνση της εκπαίδευσης: Διατηρώντας σταθερές κατανομές ενεργοποιήσεων σε όλο το δίκτυο, η ομαδοποίηση παρτίδας επιτρέπει υψηλότερους ρυθμούς μάθησης, οδηγώντας σε ταχύτερη σύγκλιση κατά την εκπαίδευση.
2. Μειωμένη ευαισθησία στην αρχικοποίηση: Η ομαλοποίηση παρτίδας μετριάζει την εξάρτηση από την προσεκτική αρχικοποίηση των παραμέτρων, καθιστώντας ευκολότερη την εκπαίδευση βαθιών δικτύων.
3. Επίδραση κανονικοποίησης: Ο θόρυβος που εισάγει η ομαδοποίηση κατά τη διάρκεια της εκπαίδευσης έχει ένα ελαφρύ αποτέλεσμα κανονικοποίησης, το οποίο μπορεί να μειώσει την ανάγκη για άλλες τεχνικές κανονικοποίησης.

Μελέτες έχουν δείξει ότι η ομαδοποίηση παρτίδας βελτιώνει σημαντικά την απόδοση των βαθιών δικτύων σε διάφορες εργασίες. Για παράδειγμα, οι He et al. (2016) [21] έδειξαν ότι η ομαλοποίηση παρτίδας είναι απαραίτητη για την εκπαίδευση βαθιών δικτύων, όπως το ResNet, το οποίο πέτυχε κορυφαία αποτελέσματα σε διάφορα benchmarks. Ομοίως, οι Szegedy et al. (2015) [20] ενσωμάτωσαν την κανονικοποίηση παρτίδας στην αρχιτεκτονική Inception, οδηγώντας σε σημαντικές βελτιώσεις των επιδόσεων.

Στην πράξη, η ομαλοποίηση εφαρμόζεται συνήθως μετά τα συνελκτικά ή πλήρως συνδεδεμένα στρώματα και πριν από τη συνάρτηση ενεργοποίησης. Αυτή η τοποθέτηση διασφαλίζει ότι η κανονικοποίηση πραγματοποιείται στις προ-ενεργοποιημένες εισόδους,

συμβάλλοντας σε πιο σταθερή και αποτελεσματική εκπαίδευση. Η αποτελεσματικότητα της ομαλοποίησης παρτίδας οδήγησε στην ευρεία υιοθέτησή της σε μοντέλα βαθιάς μάθησης. Η ικανότητά της να βελτιώνει την ταχύτητα εκπαίδευσης, τη σταθερότητα και τη συνολική απόδοση την καθιστά θεμελιώδες στοιχείο των σύγχρονων αρχιτεκτονικών CNN.

2.3.4 Ρυθμισμένες Γραμμικές Μονάδες

Οι ρυθμισμένες γραμμικές μονάδες (Rectified Linear Units) είναι ένα κρίσιμο συστατικό στην αρχιτεκτονική των νευρωνικών δικτύων συνελκτικής μάθησης, διαδραματίζοντας σημαντικό ρόλο στην απόδοση και την αποτελεσματικότητα της εκπαίδευσης των μοντέλων βαθιάς μάθησης. Οι συναρτήσεις ReLU εισάγουν μη γραμμικότητα στο μοντέλο, διατηρώντας παράλληλα την υπολογιστική αποδοτικότητα, γεγονός που τις καθιστά δημοφιλή επιλογή έναντι των παραδοσιακών συναρτήσεων ενεργοποίησης, όπως η σιγμοειδής ή η υπερβολική εφαπτομένη (tanh). Η συνάρτηση ενεργοποίησης ReLU ορίζεται ως:

$$F(x) = \max(0, x)$$

Αυτή η απλή λειτουργία μηδενίζει τις αρνητικές τιμές, ενώ διατηρεί τις θετικές τιμές αμετάβλητες, επιτρέποντας στο μοντέλο να διατηρεί την πληροφορία σχετικά με το μέγεθος των θετικών εισόδων, ενώ αγνοεί τις αρνητικές εισόδους. Αυτή η ιδιότητα της ReLU βοηθά στον μετριασμό του προβλήματος, το οποίο αντιμετωπίζεται συχνά με σιγμοειδείς ή tanh συναρτήσεις, όπου οι κλίσεις γίνονται υπερβολικά μικρές, επιβραδύνοντας έτσι τη διαδικασία εκπαίδευσης [6].

Πλεονεκτήματα:

1. Αραιές ενεργοποιήσεις: Η ReLU προκαλεί αραιότητα στο νευρωνικό δίκτυο θέτοντας ένα σημαντικό μέρος των εξόδων των νευρώνων στο μηδέν. Αυτή η αραιότητα οδηγεί σε πιο αποδοτικούς υπολογισμούς και μπορεί να βοηθήσει στη μείωση της υπερπροσαρμογής μειώνοντας αποτελεσματικά τη χωρητικότητα του μοντέλου [7].

2. Υπολογιστική αποδοτικότητα: Η συνάρτηση ReLU είναι υπολογιστικά λιγότερο δαπανηρή σε σύγκριση με τις συναρτήσεις sigmoid ή tanh, οι οποίες περιλαμβάνουν εκθετικούς υπολογισμούς. Η απλότητα της συνάρτησης ReLU επιτρέπει ταχύτερη εκπαίδευση και εξαγωγή συμπερασμάτων [9].

Παρά τα πλεονεκτήματά της, η συνάρτηση ενεργοποίησης ReLU παρουσιάζει αρκετές προκλήσεις που μπορούν να επηρεάσουν τη συνολική απόδοση των νευρωνικών δικτύων. Ένα από τα σημαντικότερα ζητήματα είναι το πρόβλημα του "dying ReLU" (νεκρού ReLU), όπου οι νευρώνες μπορεί να αδρανοποιηθούν και να εξάγουν μόνο μηδενικά. Αυτό το φαινόμενο συμβαίνει όταν μια μεγάλη αρνητική κλίση διαρρέει τον νευρώνα ReLU, καθιστώντας τον μόνιμα ανενεργό. Όταν ένας νευρώνας γίνεται ανενεργός, παύει να συμβάλλει στην εκμάθηση του μοντέλου, επηρεάζοντας αρνητικά τη διαδικασία εκπαίδευσης.

Στο πλαίσιο της ανάλυσης σημάτων ΗΕΓ, η χρήση συναρτήσεων ενεργοποίησης ReLU εντός των CNN έχει επιδείξει σημαντικές βελτιώσεις σε εργασίες ταξινόμησης, όπως η ανίχνευση επιληπτικών κρίσεων και άλλων νευρολογικών καταστάσεων. Η ReLU βοηθά στην αποτελεσματική εξαγωγή χαρακτηριστικών από δεδομένα EEG, τα οποία συχνά περιέχουν σήματα υψηλής διάστασης και θορύβου. Διατηρώντας το μέγεθος των θετικών σημάτων και απορρίπτοντας τον αρνητικό θόρυβο, η ReLU βοηθά στην παραγωγή μιας πιο ισχυρής αναπαράστασης χαρακτηριστικών, οδηγώντας σε υψηλότερη ακρίβεια στα μοντέλα ταξινόμησης [4].

Συμπερασματικά, η ReLU αποτελεί αναπόσπαστο μέρος του σχεδιασμού και της απόδοσης των συνελκτικών νευρωνικών δικτύων στην ανάλυση σημάτων EEG. Η ReLU προσφέρει υπολογιστική αποδοτικότητα και αποτελεσματική διάδοση κλίσης, τα οποία είναι απαραίτητα για τον χειρισμό της πολυπλοκότητας και της υψηλής διαστατικότητας των δεδομένων EEG. Η ικανότητά της να φιλτράρει αποτελεσματικά τον θόρυβο και να εξάγει κρίσιμα χαρακτηριστικά την καθιστά ιδανική για εφαρμογές που απαιτούν ακριβή ανίχνευση και διάγνωση νευρολογικών καταστάσεων, όπως η ανίχνευση επιληπτικών κρίσεων. Με την προσαρμογή και τη χρήση των παραλλαγών της ReLU, μπορούμε να βελτιώσουμε περαιτέρω την απόδοση των μοντέλων, καθιστώντας τα συνελκτικά νευρωνικά δίκτυα πιο αποτελεσματικά και αξιόπιστα στην ανάλυση σημάτων EEG.

2.3.5 Πλήρως Συνδεδεμένα Στρώματα

Τα πλήρως συνδεδεμένα στρώματα, γνωστά και ως πυκνά στρώματα, είναι θεμελιώδη συστατικά των νευρωνικών δικτύων με συνελικτική σύνδεση και διαδραματίζουν κρίσιμο ρόλο στα τελικά στάδια του δικτύου. Αυτά τα στρώματα είναι υπεύθυνα για την αντιστοίχιση των υψηλού επιπέδου, αφηρημένων χαρακτηριστικών που εξάγονται από τα προηγούμενα στρώματα στην τελική έξοδο, η οποία μπορεί να είναι ταξινόμηση, παλινδρόμηση ή άλλοι τύποι προβλέψεων. Τα πλήρως συνδεδεμένα στρώματα συνδέουν κάθε νευρώνα σε ένα στρώμα με κάθε νευρώνα στο επόμενο στρώμα, επιτρέποντας έτσι στο δίκτυο να συνδυάσει όλα τα χαρακτηριστικά που εξάγονται από τα στρώματα συνελίξεων και συγκέντρωσης για να λάβει μια τελική απόφαση.

Σε ένα πλήρως συνδεδεμένο επίπεδο, κάθε είσοδος συνδέεται με κάθε έξοδο με ένα βάρος και η έξοδος υπολογίζεται ως σταθμισμένο άθροισμα των εισόδων ακολουθούμενο από μια συνάρτηση ενεργοποίησης. Μαθηματικά, αυτό μπορεί να αναπαρασταθεί ως εξής:

$$y = f(Wx + b)$$

όπου W είναι ο πίνακας βαρών, x είναι το διάνυσμα εισόδου, b είναι το διάνυσμα μεροληψίας, και f είναι η συνάρτηση ενεργοποίησης. Αυτή η πυκνή συνδεσιμότητα επιτρέπει στο μοντέλο να μαθαίνει σύνθετες σχέσεις μεταξύ των εξαγόμενων χαρακτηριστικών και των στόχων [9].

Ρόλος στα CNN:

Τα πλήρως συνδεδεμένα στρώματα τοποθετούνται συνήθως στο τέλος ενός CNN, μετά από διάφορα επίπεδα συνελίξεως. Ο πρωταρχικός τους ρόλος είναι να ενσωματώνουν τις χωρικά καταναεμημένες πληροφορίες που συλλέγονται από τα προηγούμενα στρώματα σε μια μορφή κατάλληλη για την τελική έξοδο, είτε πρόκειται για βαθμολογία κλάσης σε εργασίες ταξινόμησης είτε για άλλες μορφές προβλέψεων. Με τον τρόπο αυτό, μετατρέπουν τους χάρτες χαρακτηριστικών στην επιθυμητή μορφή εξόδου.

Σημασία στην ανάλυση σήματος EEG:

Στο πλαίσιο της ανάλυσης σήματος EEG, τα πλήρως συνδεδεμένα στρώματα έχουν καθοριστική σημασία για τη σύνθεση των πληροφοριών από τα στρώματα εξαγωγής χαρακτηριστικών. Τα δεδομένα EEG είναι εξαιρετικά πολύπλοκα και περιέχουν πλούσιες χρονικές και φασματικές πληροφορίες. Τα συνεπτυγμένα στρώματα συλλαμβάνουν τοπικά μοτίβα, ενώ τα πλήρως συνδεδεμένα στρώματα ενσωματώνουν αυτά τα μοτίβα για να κάνουν σφαιρικές προβλέψεις. Αυτό είναι ιδιαίτερα σημαντικό για εργασίες όπως η ανίχνευση επιληπτικών κρίσεων, όπου η απόφαση πρέπει να βασίζεται σε μια ολοκληρωμένη κατανόηση των σημάτων EEG σε διαφορετικά κανάλια και χρονικά πλαίσια [6].

Πλεονεκτήματα:

1. Συνδυασμός χαρακτηριστικών: Τα πλήρως συνδεδεμένα στρώματα επιτρέπουν τον συνδυασμό των χαρακτηριστικών που έχουν εξάγει τα προηγούμενα στρώματα, ενσωματώνοντας τις πληροφορίες από διαφορετικές περιοχές του σήματος. Αυτό είναι ζωτικής σημασίας για εργασίες που απαιτούν ενσωμάτωση πληροφοριών από διάφορες πηγές [7].
2. Εκμάθηση σύνθετων αναπαραστάσεων: Τα πλήρως συνδεδεμένα στρώματα επιτρέπουν στο δίκτυο να μαθαίνει σύνθετες, μη γραμμικές αναπαραστάσεις συνδυάζοντας χαρακτηριστικά με διάφορους τρόπους. Αυτό ενισχύει την ικανότητα του μοντέλου να συλλαμβάνει περίπλοκα μοτίβα στα δεδομένα, αυξάνοντας την ακρίβεια των προβλέψεων [8].

Προκλήσεις

1. Υπερπροσαρμογή: Η υψηλή συνδεσιμότητα των πλήρως συνδεδεμένων στρωμάτων αυξάνει τον κίνδυνο υπερπροσαρμογής, ιδίως όταν τα δεδομένα εκπαίδευσης είναι περιορισμένα. Για να μετριαστεί αυτό το πρόβλημα, χρησιμοποιούνται συχνά τεχνικές κανονικοποίησης [3].

2. Υπολογιστικό κόστος: Ο μεγάλος αριθμός συνδέσεων μπορεί να οδηγήσει σε υψηλό υπολογιστικό κόστος, ιδίως σε βαθιά δίκτυα με πλήρως συνδεδεμένα στρώματα. Οι αποδοτικές υλοποιήσεις είναι συχνά απαραίτητες για τη διαχείριση αυτού του κόστους [4].

Κατά τον σχεδιασμό του CNN για την ανάλυση σήματος EEG, πρέπει να λαμβάνεται προσεκτικά υπόψη η αρχιτεκτονική των πλήρως συνδεδεμένων στρωμάτων. Ο αριθμός των νευρώνων, ο τύπος των συναρτήσεων ενεργοποίησης και η χρήση τεχνικών κανονικοποίησης παίζουν καθοριστικό ρόλο στην απόδοση του δικτύου. Μελέτες έχουν δείξει ότι η λεπτομερής ρύθμιση αυτών των παραμέτρων μπορεί να βελτιώσει σημαντικά την ακρίβεια και την ευρωστία των προβλέψεων με βάση το EEG [12].

2.3.6 Στρώμα Εισόδου Ακολουθίας

Τα συνελκτικά νευρωνικά δίκτυα αποτελούν έναν από τους πιο δημοφιλείς και αποτελεσματικούς τύπους τεχνητών νευρωνικών δικτύων για την ανάλυση σημάτων, όπως τα EEG. Ένα από τα βασικά στοιχεία της αρχιτεκτονικής ενός CNN είναι το στρώμα εισόδου ακολουθίας (Sequence Input Layer), το οποίο είναι υπεύθυνο για την αρχική λήψη και κανονικοποίηση των δεδομένων εισόδου. Το στρώμα εισόδου ακολουθίας δέχεται τα σήματα EEG σε μορφή χρονοσειράς, με διαστάσεις 1×4097 . Η κανονικοποίηση των δεδομένων πραγματοποιείται με τη χρήση της παραμέτρου "MinLength", η οποία εξασφαλίζει ότι οι είσοδοι έχουν ελάχιστο μήκος, επιτρέποντας στο δίκτυο να διαχειρίζεται σωστά τις χρονοσειρές. Αυτό είναι ιδιαίτερα σημαντικό για την ανάλυση των σημάτων EEG, τα οποία συχνά παρουσιάζουν μεταβλητότητα στη διάρκεια και τη μορφή τους. Η χρήση στρώματος εισόδου ακολουθίας επιτρέπει την αποτελεσματική κανονικοποίηση και προεπεξεργασία των δεδομένων, παρέχοντας μια σταθερή βάση για τα επόμενα στρώματα του δικτύου. Τα συνελκτικά στρώματα που ακολουθούν είναι σε θέση να εξάγουν πολύπλοκα τοπικά χαρακτηριστικά από τα δεδομένα εισόδου, χάρη στην κανονικοποίηση που προσφέρει το στρώμα εισόδου ακολουθίας.

Οι Gehring et al. (2017) [26] περιγράφουν τη χρήση ενός CNN για την επεξεργασία ακολουθιών, υπογραμμίζοντας την αποτελεσματικότητα της παράλληλης επεξεργασίας των στοιχείων της ακολουθίας και την ευκολία εκπαίδευσης του δικτύου. Αυτό οφείλεται στη σταθερή και ανεξάρτητη από το μήκος εισόδου χρήση μη γραμμικών συναρτήσεων, που καθιστούν την εκπαίδευση πιο αποδοτική και απλή. Αυτή η προσέγγιση αποδεικνύεται ιδιαίτερα χρήσιμη για την ανάλυση σημάτων EEG, όπου η ποικιλία στη διάρκεια των σημάτων μπορεί να αποτελέσει πρόκληση. Επιπλέον αναδεικνύεται [27] η σημασία της κανονικοποίησης και της σταθεροποίησης της μεταβλητότητας των σημάτων μέσω της χρήσης τεχνικών όπως το "MinLength". Η κανονικοποίηση εξασφαλίζει ότι τα δεδομένα εισόδου είναι ομοιόμορφα και έτοιμα για την επεξεργασία από τα συνελκτικά στρώματα, τα οποία εξάγουν τα βασικά χαρακτηριστικά για την περαιτέρω ανάλυση και ταξινόμηση των σημάτων EEG.

Τέλος, η μελέτη του Bai et al. (2018) [28] τονίζει τη σημασία της επεξεργασίας ακολουθιών με τη χρήση CNNs και αναδεικνύει την αποτελεσματικότητα αυτής της προσέγγισης στην ανάλυση χρονοσειρών, όπως τα σήματα EEG, παρέχοντας ισχυρά και αξιόπιστα αποτελέσματα.

Η χρήση στρώματος εισόδου ακολουθίας στα CNNs για την ανάλυση σημάτων EEG προσφέρει πολυάριθμα πλεονεκτήματα, όπως:

1. Σταθεροποίηση της Εισόδου: Η κανονικοποίηση εξασφαλίζει ότι τα σήματα εισόδου είναι σταθερά και ομοιόμορφα, διευκολύνοντας την επεξεργασία τους από τα επόμενα στρώματα.
2. Αποτελεσματική Εξαγωγή Χαρακτηριστικών: Τα συνελκτικά στρώματα που ακολουθούν μπορούν να εξάγουν με ακρίβεια τα σημαντικά χαρακτηριστικά από τα κανονικοποιημένα σήματα.
3. Βελτίωση της Απόδοσης: Η κανονικοποίηση και η σταθεροποίηση των εισόδων συμβάλλουν στη βελτίωση της απόδοσης του δικτύου, μειώνοντας την πιθανότητα σφαλμάτων και βελτιώνοντας την ακρίβεια της ταξινόμησης.

Η κατανόηση και η σωστή εφαρμογή του στρώματος εισόδου ακολουθίας είναι κρίσιμη για την επιτυχή ανάλυση και επεξεργασία σημάτων EEG με τη χρήση CNNs, προσφέροντας αξιόπιστες και ακριβείς προβλέψεις και αναλύσεις.

Η εφαρμογή του στρώματος εισόδου ακολουθίας στα CNNs έχει αποδειχθεί ιδιαίτερα χρήσιμη σε πολλές εφαρμογές, όπως η ανίχνευση επιληπτικών κρίσεων, η κατηγοριοποίηση νευρολογικών διαταραχών και η παρακολούθηση γνωστικών καταστάσεων. Η δυνατότητα προσαρμογής σε δεδομένα διαφορετικών μηκών καθιστά τα CNNs ευέλικτα και ισχυρά εργαλεία για την ανάλυση σημάτων EEG.

Με την προσθήκη του στρώματος εισόδου ακολουθίας, τα CNNs μπορούν να επεξεργαστούν αποτελεσματικά χρονοσειρές και να εξάγουν πολύτιμα χαρακτηριστικά, οδηγώντας σε ακριβείς και αξιόπιστες αναλύσεις. Αυτό έχει άμεσες εφαρμογές σε κλινικές και ερευνητικές συνθήκες, βελτιώνοντας την κατανόηση και τη διάγνωση νευρολογικών καταστάσεων.

2.3.7 Χρήση Βαρών στις Κλάσεις (Class Weights):

Η χρήση βαρών στις κλάσεις αποτελεί μια κρίσιμη τεχνική στην εκπαίδευση νευρωνικών δικτύων, ειδικά όταν τα δεδομένα είναι ανισόρροπα. Σε πολλές περιπτώσεις, τα δεδομένα εκπαίδευσης περιλαμβάνουν κλάσεις με διαφορετική συχνότητα εμφάνισης, προκαλώντας μεροληψία του μοντέλου υπέρ των συχνότερων κλάσεων και μειώνοντας την ακρίβεια στις σπανιότερες κλάσεις. Τα βάρη στις κλάσεις αντιμετωπίζουν αυτό το πρόβλημα δίνοντας μεγαλύτερη έμφαση στις σπανιότερες κλάσεις κατά τη διάρκεια της εκπαίδευσης.

Όταν τα δεδομένα εκπαίδευσης περιλαμβάνουν κλάσεις με διαφορετική συχνότητα εμφάνισης, το νευρωνικό δίκτυο τείνει να μαθαίνει καλύτερα τις συχνότερες κλάσεις και να αγνοεί τις σπανιότερες. Αυτό μπορεί να οδηγήσει σε μοντέλα που αποδίδουν καλά στις συχνότερες κλάσεις αλλά αποτυγχάνουν να ανιχνεύσουν τις σπανιότερες. Για να αντιμετωπιστεί αυτό το πρόβλημα, χρησιμοποιούνται τα βάρη στις κλάσεις. Τα βάρη κλάσεων προσαρμόζουν την συνάρτηση κόστους κατά την εκπαίδευση, δίνοντας μεγαλύτερη έμφαση στις σπανιότερες κλάσεις. Έτσι, το δίκτυο αναγκάζεται να μάθει και να γενικεύσει καλύτερα για όλες τις κλάσεις.

Τα βάρη κλάσεων μπορούν να υπολογιστούν με βάση την συχνότητα εμφάνισης κάθε κλάσης στο σετ δεδομένων εκπαίδευσης. Ένας κοινός τρόπος υπολογισμού είναι ο εξής:

$$ClassWeight_i = \frac{N}{C \cdot n_i}$$

όπου:

- N είναι ο συνολικός αριθμός των παραδειγμάτων,
- C είναι ο αριθμός των κλάσεων,
- n_i είναι ο αριθμός των παραδειγμάτων της κλάσης i .

Η χρήση βαρών στις κλάσεις έχει αποδειχθεί ότι βελτιώνει την απόδοση των μοντέλων σε περιπτώσεις ανισοκατανομημένων δεδομένων, καθιστώντας τα πιο γενικεύσιμα και ακριβή σε όλες τις κατηγορίες. Με τον τρόπο αυτό, εξασφαλίζεται ότι το δίκτυο θα είναι ικανό να αναγνωρίζει και να ταξινομεί σωστά ακόμα και τις λιγότερο συχνές κλάσεις, βελτιώνοντας την συνολική του απόδοση.

Η θεωρητική αυτή βάση υποστηρίζεται από τη βιβλιογραφία, όπως αναφέρεται στο έργο των Miltiadous et al. (2022) [22], που εξετάζει αλγορίθμους μηχανικής μάθησης για την ανίχνευση επιληψίας με χρήση δημοσιευμένων βάσεων δεδομένων EEG, και στο έργο των Ioffe και Szegedy (2015) [20], που αναφέρεται στην κανονικοποίηση παρτίδων για την επιτάχυνση της εκπαίδευσης βαθιών δικτύων.

2.4 Εφαρμογές των Νευρωνικών Δικτύων στην Ανάλυση Σημάτων EEG

Τα Συνελικτικά Νευρωνικά Δίκτυα έχουν εφαρμοστεί επιτυχώς σε πολλές εφαρμογές ανάλυσης σημάτων EEG, προσφέροντας σημαντικές προόδους στον τομέα της ιατρικής διάγνωσης, της νευροεπιστήμης και της έρευνας εγκεφάλου. Η ικανότητα των CNNs να εξάγουν σύνθετα χαρακτηριστικά και να αναγνωρίζουν πρότυπα από μεγάλα και πολυδιάστατα σύνολα δεδομένων τα καθιστά ιδανικά για την επεξεργασία και ανάλυση σημάτων EEG, τα οποία περιέχουν πλούσιες πληροφορίες σχετικά με τη νευρική δραστηριότητα.

Τα δεδομένα EEG είναι ιδιαίτερα πολύπλοκα και συχνά περιέχουν θόρυβο και σήματα που περιέχουν παράσιτα, καθιστώντας την ανάλυση τους μια προκλητική εργασία. Ωστόσο, τα CNNs έχουν επιδείξει εξαιρετική απόδοση σε αυτή την κατεύθυνση, επιτρέποντας την ανάπτυξη προηγμένων μεθόδων για την ακριβή και αξιόπιστη ανάλυση των σημάτων EEG. Οι εφαρμογές των CNNs στην ανάλυση σημάτων περιλαμβάνουν την κατηγοριοποίηση και αναγνώριση συμπτωμάτων, την ανίχνευση και καταπολέμηση παρασιτικών σημάτων, την ανάλυση συμπεριφοράς και κατάστασης, καθώς και την ανάπτυξη συστημάτων εγκεφαλικού ελέγχου.

Η κατηγοριοποίηση και αναγνώριση συμπτωμάτων μέσω σημάτων EEG με τη χρήση CNNs έχει οδηγήσει σε σημαντικές προόδους στη διάγνωση και θεραπεία νευρολογικών διαταραχών. Επιπλέον, η ικανότητα των CNNs να ανιχνεύουν και να καταπολεμούν παρασιτικά σήματα βελτιώνει την ακρίβεια της ανάλυσης, ενώ η ανάλυση της συμπεριφοράς και της κατάστασης παρέχει σημαντικές πληροφορίες για τη γνωστική και ψυχολογική κατάσταση των ατόμων. Τέλος, τα συστήματα εγκεφαλικού ελέγχου που βασίζονται σε CNNs ανοίγουν νέες δυνατότητες για την αλληλεπίδραση μεταξύ του ανθρώπινου εγκεφάλου και των εξωτερικών συσκευών, βελτιώνοντας την ποιότητα ζωής των ατόμων με αναπηρίες. Οι εφαρμογές αυτές περιλαμβάνουν:

1. Κατηγοριοποίηση και Αναγνώριση Συμπτωμάτων

Η εφαρμογή των Συνελικτικών Νευρωνικών Δικτύων (CNNs) στην ανάλυση σημάτων EEG αναδεικνύει τον τεράστιο δυναμικό τους στην κατηγοριοποίηση διαφόρων κατηγοριών εγκεφαλικής δραστηριότητας. Η ικανότητά τους να εξάγουν χαρακτηριστικά από πολύπλοκα δεδομένα τα καθιστά ιδιαίτερα αποτελεσματικά στην ανίχνευση και αναγνώριση παθολογικών μοτίβων. Η έρευνα του Bhandary et al. (2020) [15] αναδεικνύει τον σημαντικό ρόλο των CNNs στην αναγνώριση και διάκριση διαφόρων τύπων επιληψίας και άλλων νευρολογικών παθήσεων. Μέσω της ανάλυσης μεγάλων ποσοτήτων δεδομένων EEG, τα CNNs εντοπίζουν κρίσιμα χαρακτηριστικά και κατηγοριοποιούν τα σήματα με υψηλή ακρίβεια, βοηθώντας στην πρόβλεψη επιληπτικών κρίσεων και στη διάγνωση νευρολογικών διαταραχών. Η ικανότητά τους να ανιχνεύουν λεπτές αλλαγές στη νευρωνική δραστηριότητα επιτρέπει την καλύτερη προσαρμογή των θεραπευτικών πρωτοκόλλων στις

ανάγκες του κάθε ασθενούς, βελτιώνοντας την αποτελεσματικότητα της θεραπείας και μειώνοντας τις ανεπιθύμητες ενέργειες.

2. Ανίχνευση και Καταπολέμηση Παρασιτικών Σημάτων

Η ανίχνευση και καταπολέμηση παρασιτικών σημάτων στα EEG αποτελεί μία από τις πιο σημαντικές προκλήσεις στην ανάλυση εγκεφαλικής δραστηριότητας. Τα παρασιτικά σήματα (artifacts) μπορεί να προέρχονται από διάφορες πηγές, όπως οι κινήσεις των ματιών, οι μυϊκές συσπάσεις και τα περιβαλλοντικά ηλεκτρομαγνητικά σήματα, και μπορούν να επηρεάσουν σημαντικά την ακρίβεια των αναλύσεων. Η μελέτη του Gharaee et al. (2021) [16] επικεντρώνεται στην ανάπτυξη ενός δικτύου βαθιάς μάθησης για την ανίχνευση και την απομάκρυνση αυτών των παρασιτικών σημάτων από τα σήματα EEG. Τα παρασιτικά σήματα αποτελούν σοβαρό πρόβλημα στην ανάλυση EEG, καθώς μπορούν να συγκαλύψουν τα πραγματικά νευρωνικά σήματα και να οδηγήσουν σε εσφαλμένες διαγνώσεις ή ανακριβείς μετρήσεις της εγκεφαλικής δραστηριότητας. Οι παραδοσιακές μέθοδοι ανίχνευσης και αφαίρεσης παρασιτικών σημάτων βασίζονται σε χειροκίνητες διαδικασίες ή απλούς αλγόριθμους φιλτραρίσματος, οι οποίοι συχνά δεν είναι αρκετά αποτελεσματικοί για την απομάκρυνση όλων των παρασίτων. Χρησιμοποιώντας συνελκτικά νευρωνικά δίκτυα, οι ερευνητές αναπτύσσουν μια αυτόματη διαδικασία ανίχνευσης και αφαίρεσης παρασιτικών σημάτων από τα σήματα EEG. Τα CNNs είναι ιδιαίτερα αποτελεσματικά στην εξαγωγή χαρακτηριστικών και στην ανίχνευση πολύπλοκων μοτίβων στα δεδομένα. Στην περίπτωση της ανάλυσης EEG, τα CNNs μπορούν να εκπαιδευτούν για να αναγνωρίζουν τα χαρακτηριστικά των παρασιτικών σημάτων και να τα διαχωρίζουν από τα πραγματικά νευρωνικά σήματα. Αυτή η προσέγγιση επιτρέπει την εντοπισμό και αφαίρεση ακόμα και των πιο δύσκολων παρασιτικών σημάτων, βελτιώνοντας την ποιότητα των σημάτων και επιτρέποντας την ακριβέστερη ανάλυση της εγκεφαλικής δραστηριότητας. Ένα από τα βασικά πλεονεκτήματα της χρήσης CNNs είναι η ικανότητά τους να μαθαίνουν από τα δεδομένα και να βελτιώνουν την απόδοσή τους με την πάροδο του χρόνου. Αυτό σημαίνει ότι τα CNNs μπορούν να προσαρμοστούν σε διαφορετικούς τύπους παρασίτων και να παρέχουν συνεχή βελτίωση στην ποιότητα των σημάτων EEG. Η ανίχνευση και αφαίρεση παρασιτικών σημάτων είναι ζωτικής σημασίας για την ακριβή διάγνωση και παρακολούθηση νευρολογικών διαταραχών. Η αυτοματοποιημένη διαδικασία που αναπτύχθηκε από τους ερευνητές μπορεί να ενσωματωθεί σε κλινικά συστήματα EEG, βελτιώνοντας την αξιοπιστία των μετρήσεων και μειώνοντας τον χρόνο που απαιτείται για την ανάλυση των δεδομένων. Επιπλέον, η

ικανότητα των CNNs να παρέχουν καθαρά και ακριβή δεδομένα EEG μπορεί να οδηγήσει σε καλύτερη κατανόηση των νευρολογικών καταστάσεων και στη βελτίωση των θεραπειών για τους ασθενείς.

3. Ανάλυση Συμπεριφοράς και Κατάστασης

Τα Συνελικτικά Νευρωνικά Δίκτυα εφαρμόζονται επιτυχώς στην αναγνώριση διαφόρων σταδίων της συμπεριφοράς και της κατάστασης ατόμων μέσω της ανάλυσης των σημάτων EEG. Αυτή η τεχνική μπορεί να ανιχνεύσει τα σημάδια της προσοχής, του στρες, καθώς και άλλων συναισθηματικών καταστάσεων, με βάση τα μοτίβα που παρουσιάζουν τα EEG σήματα σε κάθε κατάσταση. Η ικανότητα των CNNs να εξαγάγουν και να αναλύουν περίπλοκα χαρακτηριστικά από τα σήματα EEG τα καθιστά ιδιαίτερα αποτελεσματικά στην κατανόηση της νευρωνικής δραστηριότητας που σχετίζεται με διάφορες ψυχολογικές και φυσιολογικές καταστάσεις. Τα CNNs έχουν χρησιμοποιηθεί για την αναγνώριση μιας ποικιλίας συναισθηματικών και ψυχολογικών καταστάσεων. Για παράδειγμα, η ανίχνευση των επιπέδων προσοχής και συγκέντρωσης είναι κρίσιμη σε εκπαιδευτικά και εργασιακά περιβάλλοντα. Τα CNNs μπορούν να αναλύσουν τα σήματα EEG για να προσδιορίσουν πότε ένα άτομο είναι συγκεντρωμένο ή διασπασμένο, παρέχοντας χρήσιμες πληροφορίες για τη βελτίωση της απόδοσης και της μάθησης. Η ανίχνευση του στρες είναι μια άλλη σημαντική εφαρμογή. Σε καταστάσεις υψηλής πίεσης, όπως η εργασία, τα CNNs μπορούν να ανιχνεύσουν τα μοτίβα του στρες στα σήματα EEG και να παράσχουν ειδοποιήσεις ή προτάσεις για την αντιμετώπιση του στρες. Αυτό μπορεί να συμβάλει στη βελτίωση της ψυχικής υγείας και της ευημερίας των ατόμων. Συγκεκριμένα, έρευνα που δημοσιεύθηκε από τον A. Supratak και συνεργάτες το 2017 [17] δείχνει την αποτελεσματικότητα της μεθόδου αυτής. Η μελέτη επιβεβαιώνει ότι τα CNNs μπορούν να εφαρμοστούν με επιτυχία στον αυτόματο προσδιορισμό των σταδίων του ύπνου, με βάση τα EEG σήματα. Ο ύπνος αποτελεί μια πολύπλοκη διαδικασία που περιλαμβάνει διάφορα στάδια, όπως το στάδιο του ύπνου REM και τα στάδια του βαθύ ύπνου. Η ακριβής αναγνώριση αυτών των σταδίων είναι κρίσιμη για την κατανόηση των προβλημάτων ύπνου και την ανάπτυξη κατάλληλων θεραπειών. Η έρευνα του Supratak et al. έδειξε ότι τα CNNs μπορούν να αναγνωρίσουν τα στάδια του ύπνου με υψηλή ακρίβεια, χρησιμοποιώντας σήματα EEG. Αυτή η προσέγγιση παρέχει μια αυτοματοποιημένη και αξιόπιστη μέθοδο για την ανάλυση του ύπνου, που μπορεί να εφαρμοστεί σε κλινικά και διερευνητικά περιβάλλοντα. Η έρευνα αναδεικνύει την πρακτική αξία των CNNs στην ανάλυση των συμπεριφορών και των καταστάσεων ατόμων, παρέχοντας ένα αξιόπιστο

εργαλείο για την κατανόηση και την αξιολόγηση της ανθρώπινης νοημοσύνης και του νευρικού συστήματος. Οι εφαρμογές αυτές δεν περιορίζονται μόνο στην ιατρική διάγνωση αλλά επεκτείνονται και σε άλλους τομείς όπως η ψυχολογία, η εκπαίδευση, και η ανθρώπινη-υπολογιστική αλληλεπίδραση. Η ανάλυση των σημάτων EEG με CNNs μπορεί να χρησιμοποιηθεί για την παρακολούθηση της προόδου των ασθενών, την αξιολόγηση της αποτελεσματικότητας των θεραπευτικών παρεμβάσεων, και την κατανόηση των επιπτώσεων των διαφόρων ψυχολογικών και φυσιολογικών καταστάσεων στην εγκεφαλική δραστηριότητα.

4. Ανάπτυξη Συστημάτων Εγκεφαλικού Ελέγχου

Τα συστήματα εγκεφαλικού ελέγχου (BCIs) είναι τεχνολογίες που επιτρέπουν την αλληλεπίδραση μεταξύ του ανθρώπινου εγκεφάλου και των εξωτερικών συσκευών μέσω σημάτων EEG. Τα CNNs έχουν παίξει σημαντικό ρόλο στην ανάπτυξη αυτών των συστημάτων, επιτρέποντας την ακριβή και αξιόπιστη ανάλυση των EEG σημάτων για τον έλεγχο εξωτερικών συσκευών, όπως οι προσθετικές άκρες, τα αναπηρικά καροτσάκια, και οι υπολογιστές.

Εφαρμογές των CNNs στην Εγκεφαλική Διασύνδεση

Μέσω της ανάλυσης των σημάτων EEG και της εξαγωγής χαρακτηριστικών που σχετίζονται με τις προθέσεις και τις εντολές του χρήστη, τα CNNs επιτρέπουν την αποτελεσματική και ακριβή επικοινωνία μεταξύ του εγκεφάλου και των συσκευών. Αυτό βελτιώνει την ποιότητα ζωής των ατόμων με αναπηρίες, επιτρέποντάς τους να εκτελούν καθημερινές δραστηριότητες με μεγαλύτερη ευκολία και αυτονομία. Για παράδειγμα, τα CNNs μπορούν να αναλύσουν τα σήματα EEG για να εντοπίσουν τις προθέσεις του χρήστη να μετακινήσει ένα προσθετικό άκρο ή να δώσει εντολές σε έναν υπολογιστή.

Έρευνες και Μελέτες

Σύμφωνα με μια μελέτη των Xinbin Liang και συνεργατών (2023) [25], τα CNNs έχουν τη δυνατότητα να βελτιώσουν σημαντικά την ακρίβεια της ταξινόμησης σημάτων EEG μέσω της χρήσης ειδικών μονάδων τοπογραφικής αναπαράστασης (TRMs). Αυτές οι μονάδες επιτρέπουν στα CNNs να αναγνωρίζουν και να εξαγάγουν χωρικές τοπογραφικές

πληροφορίες από τα σήματα EEG, βελτιώνοντας την απόδοση των συστημάτων BCI σε διάφορες εφαρμογές.

Πρακτική Αξία των CNNs

Τα CNNs προσφέρουν υψηλή ακρίβεια και ταχύτητα στην ανάλυση των σημάτων EEG, επιτρέποντας τη γρήγορη και αξιόπιστη ανίχνευση των προθέσεων του χρήστη. Αυτό είναι ιδιαίτερα σημαντικό για τα συστήματα BCI, όπου η ταχύτητα και η ακρίβεια είναι κρίσιμες για την αποτελεσματική λειτουργία τους. Τα CNNs μπορούν επίσης να προσαρμοστούν σε διάφορους τύπους σημάτων και περιβάλλοντα, καθιστώντας τα κατάλληλα για ένα ευρύ φάσμα εφαρμογών BCI. Η χρήση των CNNs για την ανάπτυξη συστημάτων BCI έχει ανοίξει νέους δρόμους για την κατανόηση της εγκεφαλικής δραστηριότητας και την αλληλεπίδραση με εξωτερικές συσκευές. Η ικανότητα των CNNs να εξάγουν κρίσιμες πληροφορίες από τα σήματα EEG και να παρέχουν ακριβείς προβλέψεις και αναλύσεις έχει συμβάλλει σημαντικά στην επιστημονική έρευνα. Αυτό έχει οδηγήσει σε νέες θεραπείες και τεχνολογίες που βελτιώνουν την ποιότητα ζωής των ατόμων με κινητικές αναπηρίες και άλλες νευρολογικές διαταραχές.

Κεφάλαιο 3

Υλοποίηση Συστήματος

3.1 Εισαγωγή

Στο κεφάλαιο αυτό παρουσιάζεται η διαδικασία υλοποίησης του συστήματος ανάλυσης σημάτων EEG με χρήση του τελικού μοντέλου συνελκτικού νευρωνικού δικτύου. Αρχικά, περιγράφονται τα δεδομένα που χρησιμοποιήθηκαν, η προεπεξεργασία τους και η σχεδίαση του τελικού μοντέλου CNN. Στη συνέχεια, αναλύεται η διαδικασία εκπαίδευσης του μοντέλου, καθώς και οι τεχνικές που εφαρμόστηκαν για την ενίσχυση της απόδοσής του. Τέλος, περιγράφεται η εφαρμογή του συστήματος σε πραγματικό χρόνο και τα εργαλεία που χρησιμοποιήθηκαν για την υλοποίησή του. Στο κεφάλαιο 4 θα συζητηθούν οι συγκρίσεις με τα άλλα μοντέλα.

3.2 Προετοιμασία και Φόρτωση Δεδομένων

Η προετοιμασία των δεδομένων αποτελεί ένα κρίσιμο βήμα στην ανάπτυξη και εκπαίδευση του συστήματος ανάλυσης σημάτων EEG. Στην παρούσα μελέτη, χρησιμοποιήθηκε ένα μεγάλο σύνολο δεδομένων EEG που περιλαμβάνει καταγραφές από φυσιολογικούς εθελοντές υπό διαφορετικές συνθήκες (με ανοικτά και κλειστά μάτια) και καταγραφές από ασθενείς με επιληψία και χωρίς.

3.2.1 Κατέβασμα και Αποσυμπίεση Δεδομένων

Για την προετοιμασία των δεδομένων, ακολουθούνται τα εξής βήματα:

1. Δημιουργία Φακέλου Αποθήκευσης:
 - Ξεκινάμε με τη δημιουργία ενός ειδικού φακέλου στον υπολογιστή, ο οποίος θα χρησιμοποιηθεί για την αποθήκευση όλων των δεδομένων EEG που θα ληφθούν

2. Κατέβασμα Αρχείων:

- Από τον παρακάτω σύνδεσμο, κατεβάζουμε τα αρχεία zip που περιέχουν τα δεδομένα EEG. Είναι σημαντικό να βεβαιωθούμε ότι έχουμε κατεβάσει όλα τα απαραίτητα αρχεία για να έχουμε πλήρη πρόσβαση στα δεδομένα.

3. Αποσυμπίεση Αρχείων:

- Τα αρχεία zip που κατεβάσαμε αποσυμπιέζονται στον φάκελο που δημιουργήθηκε στο πρώτο βήμα.

4. Επαλήθευση Δεδομένων:

- Μετά την αποσυμπίεση, ελέγχουμε τα περιεχόμενα του φακέλου για να επιβεβαιώσουμε ότι όλα τα απαραίτητα αρχεία έχουν αποθηκευτεί σωστά και δεν υπάρχουν ελλείψεις ή σφάλματα στη διαδικασία κατεβάσματος και αποσυμπίεσης.

Τα δεδομένα μπορούν να ληφθούν από την παρακάτω διεύθυνση: [Download EEG Data](#).

Ακολουθώντας αυτά τα βήματα, διασφαλίζουμε ότι τα δεδομένα μας είναι σωστά προετοιμασμένα και έτοιμα για ανάλυση με τα νευρωνικά δίκτυα που θα χρησιμοποιηθούν στην έρευνα.

Αναλυτικά ο κώδικας είναι διαθέσιμος στην παρακάτω διεύθυνση: [EEG Seizure Detection](#)

3.2.2 Οργάνωση και Κατηγοριοποίηση Δεδομένων

Μετά την αποσυμπίεση, τα δεδομένα οργάνωνονται σε φακέλους ανάλογα με την κατηγορία τους. Κάθε αρχείο zip περιέχει δεδομένα από διαφορετικές καταστάσεις και δραστηριότητες του εγκεφάλου. Η οργάνωση των δεδομένων είναι ως εξής:

1. Αρχείο Z.zip (A):

- Κατηγορία: Φυσιολογικοί εθελοντές με ανοιχτά μάτια
- Περιγραφή: Τα δεδομένα αυτά αντιπροσωπεύουν την εγκεφαλική δραστηριότητα σε κατάσταση εγρήγορσης, παρέχοντας πληροφορίες για

την τυπική λειτουργία του εγκεφάλου όταν τα άτομα είναι ξύπνια και αντιλαμβάνονται το περιβάλλον τους.

2. Αρχείο O.zip (B):

- Κατηγορία: Φυσιολογικοί εθελοντές με κλειστά μάτια
- Περιγραφή: Αυτά τα δεδομένα προσφέρουν πληροφορίες για την εγκεφαλική δραστηριότητα κατά τη διάρκεια ανάπαυσης χωρίς εξωτερικά οπτικά ερεθίσματα, επιτρέποντας τη μελέτη της εγκεφαλικής λειτουργίας σε συνθήκες χαλάρωσης.

3. Αρχείο N.zip (C):

- Κατηγορία: Φυσιολογικοί εθελοντές σε ηρεμία
- Περιγραφή: Τα δεδομένα αυτά παρέχουν μια βάση σύγκρισης για την ανάλυση εγκεφαλικών δραστηριοτήτων υπό κανονικές συνθήκες, χωρίς ιδιαίτερα ερεθίσματα ή δράσεις, λειτουργώντας ως μέτρο αναφοράς για τις υπόλοιπες κατηγορίες.

4. Αρχείο F.zip (D):

- Κατηγορία: Ασθενείς με επιληψία κατά τη διάρκεια κρίσεων
- Περιγραφή: Αυτά τα δεδομένα είναι κρίσιμα για την κατανόηση και ανίχνευση των επιληπτικών επεισοδίων, καταγράφοντας την εγκεφαλική δραστηριότητα κατά τη διάρκεια κρίσεων και βοηθώντας στην ανάπτυξη μεθόδων έγκαιρης ανίχνευσης.

5. Αρχείο S.zip (E):

- Κατηγορία: Ασθενείς με επιληψία εκτός κρίσεων
- Περιγραφή: Τα δεδομένα αυτά επιτρέπουν τη μελέτη της εγκεφαλικής δραστηριότητας σε περιόδους μεταξύ των επιληπτικών επεισοδίων, βοηθώντας στην ανάλυση της λειτουργίας του εγκεφάλου κατά τη διάρκεια της φυσιολογικής κατάστασης για ασθενείς με επιληψία.

Αυτή η κατηγοριοποίηση επιτρέπει τη σωστή ταξινόμηση και ανάλυση των δεδομένων κατά την εκπαίδευση του νευρωνικού δικτύου, εξασφαλίζοντας ότι το σύστημα μπορεί να διακρίνει με ακρίβεια μεταξύ διαφορετικών καταστάσεων και να παρέχει αξιόπιστες προβλέψεις και ανιχνεύσεις.

3.3 Κατασκευή του Νευρωνικού Δικτύου

Σε αυτή την ενότητα θα περιγράψουμε τη διαδικασία κατασκευής του τελικού νευρωνικού δικτύου που χρησιμοποιήθηκε για την ταξινόμηση των σημάτων EEG.

3.3.1 Αρχιτεκτονική Νευρωνικού Δικτύου για Ταξινόμηση Σημάτων EEG

Η αρχιτεκτονική του νευρωνικού δικτύου που αναπτύχθηκε για την ταξινόμηση των σημάτων EEG βασίζεται σε συνελκτικά νευρωνικά δίκτυα και έχει σχεδιαστεί για να επεξεργάζεται τις χρονικές σειρές των σημάτων EEG και να εξάγει σημαντικά χαρακτηριστικά για την ταξινόμηση των διαφόρων καταστάσεων του εγκεφάλου. Η αρχιτεκτονική του δικτύου περιλαμβάνει τα εξής βασικά στρώματα:

1. Στρώμα Εισόδου Ακολουθίας (Sequence Input Layer): Το πρώτο στρώμα είναι ένα στρώμα εισόδου ακολουθίας που δέχεται τα σήματα EEG. Το σήμα εισόδου έχει διαστάσεις 1×4097 και χρησιμοποιείται η κανονικοποίηση "MinLength". Αυτό το στρώμα εξασφαλίζει ότι τα δεδομένα εισόδου είναι σε κατάλληλη μορφή για την επεξεργασία από τα επόμενα στρώματα του δικτύου.
2. Συνελκτικά Στρώματα (Convolutional Layers): Τα επόμενα στρώματα είναι συνελκτικά στρώματα τα οποία εφαρμόζουν φίλτρα σε μικρά τμήματα των δεδομένων για να εξάγουν τοπικά χαρακτηριστικά. Το πρώτο συνελκτικό στρώμα είναι 1D. Η χρήση αυτών των στρωμάτων επιτρέπει την ανίχνευση τοπικών μοτίβων και χαρακτηριστικών στα σήματα EEG, όπως αιχμές και κύματα, που είναι κρίσιμα για την κατανόηση και την ταξινόμηση των διαφορετικών καταστάσεων του εγκεφάλου. Αυτά τα συνελκτικά στρώματα συμβάλλουν στην αύξηση της χωρικής ανάλυσης και στην βελτίωση της απόδοσης του δικτύου.
3. Στρώμα Συνεχούς Μετασχηματισμού Κυματιδίου (CWT Layer): Το στρώμα αυτό εφαρμόζει τον συνεχή μετασχηματισμό κυματιδίου στα σήματα EEG, βοηθώντας στην ανάλυση των σημάτων σε διαφορετικές συχνότητες και χρονικές κλίμακες. Ο μετασχηματισμός αυτός είναι ιδιαίτερα χρήσιμος για την ανίχνευση και ανάλυση μη

στατικών σημάτων, όπως τα EEG, που περιλαμβάνουν σημαντικές πληροφορίες σε διάφορες συχνότητες και χρόνους. Η χρήση του CWT επιτρέπει την εξαγωγή πλούσιων χαρακτηριστικών από τα σήματα EEG, βελτιώνοντας την ικανότητα του νευρωνικού δικτύου να αναγνωρίζει πολύπλοκα μοτίβα και καταστάσεις του εγκεφάλου.

4. Στρώματα Συγκέντρωσης (Max Pooling Layers): Αυτά τα στρώματα μειώνουν τις διαστάσεις των χαρακτηριστικών που εξάγονται από τα συνελκτικά στρώματα, διατηρώντας τα σημαντικότερα χαρακτηριστικά και μειώνοντας την υπολογιστική πολυπλοκότητα του δικτύου. Τα στρώματα max pooling επιτρέπουν την αποδοτική μείωση των δεδομένων, διευκολύνοντας την ανίχνευση και εκμάθηση κρίσιμων μοτίβων.
5. Στρώματα Κανονικοποίησης Παρτίδας (Batch Normalization Layers): Τα στρώματα αυτά κανονικοποιούν τις εξόδους των συνελκτικών στρωμάτων και των στρωμάτων συγκέντρωσης, βελτιώνοντας τη σταθερότητα και την ταχύτητα εκπαίδευσης του δικτύου. Η κανονικοποίηση παρτίδας βοηθά στην αποφυγή υπερπροσαρμογής και στην επιτάχυνση της σύγκλισης.
6. Στρώματα Ενεργοποίησης (Activation Layers): Στα στρώματα αυτά, χρησιμοποιείται η συνάρτηση ενεργοποίησης ReLU, η οποία περιγράφηκε ως **ρυθμιζόμενες γραμμικές μονάδες** στο κεφάλαιο 2. Η ReLU εισάγει μη γραμμικότητα στο μοντέλο και επιτρέπει την εκμάθηση σύνθετων μοτίβων στα δεδομένα. Η ενεργοποίηση ReLU βοηθά στη διατήρηση της πληροφορίας των σημαντικών χαρακτηριστικών και στην ενίσχυση της ικανότητας μάθησης του δικτύου.
7. Στρώμα Επίπεδης Διάταξης (Flatten Layer): Το στρώμα αυτό μετατρέπει τις πολυδιάστατες εξόδους των συνελκτικών και υποδειγματοληψίας στρωμάτων σε μονοδιάστατο διάνυσμα, προετοιμάζοντας τα δεδομένα για τα επόμενα πλήρως συνδεδεμένα στρώματα. Η επίπεδη διάταξη επιτρέπει τη διασύνδεση των χαρακτηριστικών από διαφορετικά επίπεδα του δικτύου, διευκολύνοντας την τελική ταξινόμηση.
8. Global Average Pooling Layer: Το στρώμα αυτό εφαρμόζει μέσο όρο στις εξόδους όλων των νευρώνων, μειώνοντας περαιτέρω τις διαστάσεις και βοηθώντας στη

μείωση του κινδύνου υπερεκπαίδευσης. Το στρώμα αυτό συνδυάζει τις πληροφορίες από όλα τα χαρακτηριστικά, παρέχοντας μια πιο συμπυκνωμένη αναπαράσταση.

9. Στρώμα Απόρριψης (Dropout Layer): Το στρώμα αυτό εισάγει τυχαία απόρριψη (dropout) νευρώνων κατά την εκπαίδευση, βελτιώνοντας την ικανότητα του μοντέλου να γενικεύει σε νέα δεδομένα και μειώνοντας την πιθανότητα υπερεκπαίδευσης. Η τεχνική αυτή αποτρέπει την εξάρτηση από συγκεκριμένους νευρώνες, αυξάνοντας τη ρομποστικότητα του δικτύου.
10. Πλήρως Συνδεδεμένο Στρώμα (Fully Connected Layer): Το στρώμα αυτό συνδέει όλους τους νευρώνες της προηγούμενης στρώσης με όλους τους νευρώνες της τρέχουσας στρώσης, επιτρέποντας στο μοντέλο να συνδυάζει τα χαρακτηριστικά που έχουν εξαχθεί για την τελική ταξινόμηση. Η πλήρης συνδεσιμότητα επιτρέπει τη μάθηση σύνθετων σχέσεων μεταξύ των χαρακτηριστικών.
11. Στρώμα Softmax και Στρώμα Ταξινόμησης (Softmax and Classification Layers): Τα τελικά στρώματα είναι το στρώμα Softmax, το οποίο μετατρέπει τις εξόδους του δικτύου σε πιθανότητες, και το στρώμα ταξινόμησης, το οποίο χρησιμοποιεί τις πιθανότητες αυτές για να αποφασίσει την τελική κατηγορία στην οποία ανήκει το κάθε δείγμα. Η συνάρτηση Softmax εξασφαλίζει ότι οι προβλέψεις είναι έγκυρες πιθανότητες, ενώ το στρώμα ταξινόμησης επιτρέπει την τελική ερμηνεία των αποτελεσμάτων του δικτύου.
12. Βάρη στις Κλάσεις: Χρησιμοποιήθηκαν βάρη κλάσεων για να αντιμετωπιστεί η ανισοκατανομή των δεδομένων στις διάφορες κλάσεις. Τα βάρη υπολογίστηκαν ως ο λόγος του συνολικού αριθμού των δειγμάτων προς το γινόμενο του αριθμού των κλάσεων και του αριθμού των δειγμάτων σε κάθε κλάση. Αυτός ο υπολογισμός πολλαπλασιάζει την απώλεια της συνάρτησης κόστους με μεγαλύτερους συντελεστές για τις λιγότερο συχνές κλάσεις και μικρότερους για τις πιο συχνές.

Αυτή η πολυεπίπεδη αρχιτεκτονική επιτρέπει στο νευρωνικό δίκτυο να επεξεργάζεται και να αναλύει σύνθετα σήματα EEG, εξάγοντας σημαντικά χαρακτηριστικά που χρησιμοποιούνται για την ακριβή ταξινόμηση των διαφόρων καταστάσεων του εγκεφάλου.

Συγκεκριμένα, μπορούμε να παρατηρήσουμε τα σήματα EEG σε τρεις διαφορετικές καταστάσεις:

- Επιληπτική κρίση
- Προ-επιληπτική κατάσταση
- Φυσιολογική κατάσταση

Αυτές οι αναπαραστάσεις απεικονίζουν τα χαρακτηριστικά των σημάτων σε κάθε κατάσταση, επιτρέποντας την κατανόηση της μορφολογίας και των δυναμικών αλλαγών που εμφανίζονται κατά την διάρκεια των διαφορετικών καταστάσεων του εγκεφάλου. Οι διαφορές στη συχνότητα και στο πλάτος των σημάτων είναι εμφανείς, παρέχοντας έτσι μια οπτική επισκόπηση των χαρακτηριστικών που το νευρωνικό δίκτυο θα πρέπει να ανιχνεύσει και να ταξινομήσει.

Η χρήση του σκαλογράμματος (σχήμα 4) συμβάλλει σημαντικά σε αυτό το εγχείρημα. Το σκαλογράμμα, που αποτελεί γραφική αναπαράσταση του συνεχούς μετασχηματισμού κυματιδίου (CWT), παρέχει μια πολυδιάστατη απεικόνιση των σημάτων EEG, αναδεικνύοντας τις μεταβολές των συχνοτήτων τους με την πάροδο του χρόνου. Η δυνατότητα αυτή είναι ιδιαίτερα χρήσιμη για την ανάλυση μη στατικών σημάτων όπως τα EEG, τα οποία περιέχουν κρίσιμες πληροφορίες σε διαφορετικές συχνότητες και χρονικές κλίμακες.

Ανάλυση των Σημάτων EEG και των Σκαλογραμμάτων

1. Επιληπτική κρίση (Seizure EEG)







- **Χρονικό σήμα:** Το αριστερό διάγραμμα δείχνει το χρονικό σήμα μιας επιληπτικής κρίσης. Μπορούμε να παρατηρήσουμε έντονες αιχμές και χαοτική δραστηριότητα, χαρακτηριστικά της επιληπτικής κρίσης.
- **Σκαλογράμμα:** Το δεξιό διάγραμμα απεικονίζει το σκαλογράμμα του σήματος της επιληπτικής κρίσης. Βλέπουμε υψηλή δραστηριότητα σε ένα ευρύ φάσμα συχνοτήτων, κυρίως στις χαμηλές συχνότητες. Η έντονη χρωματική αναπαράσταση δείχνει την αυξημένη ενέργεια σε αυτές τις συχνότητες.

2. Προ-επιληπτική κατάσταση (Pre-seizure EEG)

- **Χρονικό σήμα:** Το αριστερό διάγραμμα δείχνει το χρονικό σήμα πριν από μια επιληπτική κρίση. Παρατηρείται αυξανόμενη δραστηριότητα, που υποδηλώνει την προσέγγιση μιας κρίσης.
- **Σκαλογράμμα:** Το δεξιό διάγραμμα δείχνει το σκαλογράμμα της προ-επιληπτικής κατάστασης. Υπάρχει αυξημένη δραστηριότητα σε συγκεκριμένες συχνότητες, υποδεικνύοντας τα προειδοποιητικά σημάδια μιας επιληπτικής κρίσης.

3. Φυσιολογική κατάσταση (Normal EEG)

- **Χρονικό σήμα:** Το αριστερό διάγραμμα δείχνει το χρονικό σήμα μιας φυσιολογικής κατάστασης. Το σήμα είναι πιο τακτικό και η ένταση είναι χαμηλότερη σε σχέση με τις άλλες δύο καταστάσεις.
- **Σκαλογράμμα:** Το δεξιό διάγραμμα δείχνει το σκαλογράμμα του φυσιολογικού σήματος. Οι δραστηριότητες συγκεντρώνονται κυρίως σε συγκεκριμένες συχνότητες, όπως τα κύματα άλφα (8-12 Hz), τα οποία είναι χαρακτηριστικά της φυσιολογικής εγκεφαλικής λειτουργίας.



Σχήμα 4: Scalogram

Αυτές οι απεικονίσεις βοηθούν στην καλύτερη κατανόηση των μεταβολών στα σήματα EEG, επιτρέποντας στο νευρωνικό δίκτυο να ανιχνεύει και να ταξινομεί με μεγαλύτερη ακρίβεια τις διάφορες καταστάσεις του εγκεφάλου

Με την ενσωμάτωση του σκαλογράμματος, το νευρωνικό δίκτυο μπορεί να εξάγει και να αξιοποιήσει πλούσιες χρονικές και συχνотικές πληροφορίες από τα σήματα EEG, βελτιώνοντας σημαντικά την απόδοσή του στην αναγνώριση και ταξινόμηση των διαφορετικών εγκεφαλικών καταστάσεων. Η διαδικασία αυτή όχι μόνο ενισχύει την ακρίβεια του δικτύου, αλλά και παρέχει μια βαθύτερη κατανόηση των δυναμικών αλλαγών που συμβαίνουν στον εγκέφαλο κατά τη διάρκεια διαφόρων καταστάσεων.

3.3.2 Εκπαίδευση του Νευρωνικού Δικτύου Επεξεργασίας Σημάτων EEG (SPN)

Η εκπαίδευση του νευρωνικού δικτύου επεξεργασίας σημάτων EEG (SPN) αποτελεί ένα από τα πιο κρίσιμα στάδια της ανάπτυξης του συστήματος. Στην ενότητα αυτή, περιγράφεται η διαδικασία που ακολουθήθηκε για την εκπαίδευση του δικτύου, περιλαμβάνοντας την προετοιμασία των δεδομένων εκπαίδευσης, τη ρύθμιση των υπερπαραμέτρων και τις τεχνικές για την αποφυγή της υπερεκπαίδευσης.

1. Προετοιμασία Δεδομένων Εκπαίδευσης: Τα δεδομένα που προετοιμάστηκαν στην ενότητα 3.2.2 διαχωρίστηκαν σε σύνολα εκπαίδευσης, επικύρωσης και δοκιμής. Χρησιμοποιήθηκε το 70% των δεδομένων για την εκπαίδευση, το 20% για την επικύρωση και το 10% για τη δοκιμή. Αυτός ο διαχωρισμός επιτρέπει την επαρκή εκπαίδευση του μοντέλου, την αξιολόγηση της απόδοσής του κατά τη διάρκεια της εκπαίδευσης και την τελική δοκιμή του σε δεδομένα.
2. Υπερπαραμέτροι Εκπαίδευσης: Για την εκπαίδευση του δικτύου, χρησιμοποιήθηκαν συγκεκριμένες υπερπαραμέτροι που επηρεάζουν την απόδοση του μοντέλου:

- a. Εκπαίδευση Εποχής (10): Ορίζει τον αριθμό των πλήρων περασμάτων των δεδομένων εκπαίδευσης μέσω του δικτύου.
 - b. Μέγεθος των Παρτίδων (20): Καθορίζει τον αριθμό των δειγμάτων που χρησιμοποιούνται για την ενημέρωση των παραμέτρων του δικτύου σε κάθε βήμα εκπαίδευσης.
 - c. Τεχνική Βελτιστοποίησης (Adam): Χρησιμοποιήθηκε ο αλγόριθμος Adam για 10 εποχές, με τα δεδομένα να ανακατεύονται σε κάθε εποχή (shuffle every epoch) για τη βελτίωση της γενίκευσης του μοντέλου.
 - d. Κανονικοποίηση L2 ($1e-03$): Χρησιμοποιήθηκε για να αποτρέψει την υπερπροσαρμογή, προσθέτοντας ένα ποινικό όρο στο κόστος, ο οποίος εξαρτάται από το μέγεθος των βαρών του δικτύου.
3. Τεχνικές για την Αποφυγή Υπερεκπαίδευσης: Για την αποφυγή της υπερεκπαίδευσης, χρησιμοποιήθηκαν διάφορες τεχνικές:
- a. Κανονικοποίηση Παρτίδας (Batch Normalization): Βελτιώνει τη σταθερότητα και την ταχύτητα εκπαίδευσης, κανονικοποιώντας την έξοδο κάθε στρώματος βάσει των στατιστικών της τρέχουσας παρτίδας.
 - b. Απόρριψη Νευρώνων (Dropout): Αποτρέπει την υπερπροσαρμογή, τυχαία αποκλείοντας νευρώνες κατά την εκπαίδευση, αναγκάζοντας το δίκτυο να μάθει πιο ανθεκτικές αναπαραστάσεις.
 - c. Στρώμα Υποδειγματοληψίας (Global Average Pooling): Μειώνει τον αριθμό των παραμέτρων και τηρώντας τα σημαντικότερα χαρακτηριστικά των σημάτων.
4. Διαδικασία Εκπαίδευσης: Η διαδικασία εκπαίδευσης περιλάμβανε την εκτέλεση του αλγορίθμου βελτιστοποίησης για 10 εποχές, με τα δεδομένα να ανακατεύονται σε κάθε εποχή (shuffle every epoch) για τη βελτίωση της γενίκευσης του μοντέλου. Κατά την εκπαίδευση, χρησιμοποιήθηκε το σύνολο επικύρωσης για την αξιολόγηση

της απόδοσης του μοντέλου σε κάθε εποχή και την επιλογή του καλύτερου μοντέλου βάσει της απώλειας επικύρωσης.

5. Αξιολόγηση Απόδοσης: Κατά την εκπαίδευση, παρακολουθούνταν οι μετρικές απόδοσης, όπως η απώλεια εκπαίδευσης και επικύρωσης, καθώς και η ακρίβεια ταξινόμησης. Το μοντέλο με τις καλύτερες μετρήσεις επιλέχθηκε ως το τελικό εκπαιδευμένο μοντέλο. Αυτή η δομημένη διαδικασία εκπαίδευσης εξασφαλίζει ότι το νευρωνικό δίκτυο μπορεί να μάθει τα σημαντικά χαρακτηριστικά των σημάτων EEG και να τα ταξινομή με υψηλή ακρίβεια.

3.4 Εργαλεία και Τεχνολογίες Υλοποίησης

Σε αυτήν την ενότητα παρουσιάζονται τα εργαλεία και οι τεχνολογίες που χρησιμοποιήθηκαν για την υλοποίηση του συστήματος, συμπεριλαμβανομένων των εργαλείων ανάπτυξης λογισμικού, των βιβλιοθηκών προγραμματισμού και των πλατφορμών εκτέλεσης. Η επιλογή αυτών των εργαλείων ήταν κρίσιμη για την επιτυχή υλοποίηση και την αξιολόγηση του νευρωνικού δικτύου επεξεργασίας σημάτων EEG (SPN).

Τα κύρια εργαλεία και τεχνολογίες που χρησιμοποιήθηκαν περιλαμβάνουν:

1. MATLAB: Είναι ένα από τα πιο διαδεδομένα εργαλεία για την ανάλυση δεδομένων και την ανάπτυξη αλγορίθμων μηχανικής μάθησης. Χρησιμοποιήθηκε για την ανάπτυξη και εκπαίδευση του νευρωνικού δικτύου, καθώς και για την ανάλυση και οπτικοποίηση των αποτελεσμάτων. Η ευελιξία και η ισχύς του MATLAB το καθιστούν ιδανικό για εργασίες όπως η επεξεργασία σημάτων EEG, καθώς παρέχει ένα πλούσιο σύνολο λειτουργιών για την ανάλυση και την επεξεργασία δεδομένων.
2. Deep Learning Toolbox: Παρείχε τα απαραίτητα εργαλεία για τον σχεδιασμό, την εκπαίδευση και τον έλεγχο του νευρωνικού δικτύου. Περιλαμβάνει μια πληθώρα προκατασκευασμένων αλγορίθμων και λειτουργιών που διευκολύνουν την ανάπτυξη σύνθετων μοντέλων βαθιάς μάθησης. Αυτή η βιβλιοθήκη επιτρέπει την εύκολη προσαρμογή και την ταχεία ανάπτυξη του νευρωνικού δικτύου, καθώς και τη βελτίωση της απόδοσης μέσω της χρήσης προηγμένων τεχνικών βελτιστοποίησης

και κανονικοποίησης.

3. Wavelet Toolbox : Χρησιμοποιήθηκε για την ανάλυση των σημάτων EEG με τη μέθοδο των wavelet. Αυτή η toolbox παρέχει εργαλεία για την αποσύνθεση και την ανάλυση των σημάτων σε διάφορες κλίμακες και συχνότητες, επιτρέποντας την εξαγωγή σημαντικών χαρακτηριστικών που σχετίζονται με την εγκεφαλική δραστηριότητα. Η χρήση των wavelets είναι ιδιαίτερα χρήσιμη για την ανάλυση μη στατικών σημάτων, όπως τα σήματα EEG, τα οποία περιέχουν πληροφορίες σε πολλές διαφορετικές χρονικές κλίμακες.
4. Parallel Computing Toolbox: Χρησιμοποιήθηκε για την επιτάχυνση των υπολογισμών και την εκπαίδευση του νευρωνικού δικτύου με τη χρήση παράλληλου υπολογισμού. Επιτρέπει την κατανομή των υπολογιστικών πόρων και την εκτέλεση υπολογισμών σε πολλαπλούς επεξεργαστές, μειώνοντας τον χρόνο εκπαίδευσης και βελτιώνοντας την αποδοτικότητα του συστήματος.

Κεφάλαιο 4

Αξιολόγηση του Συστήματος και Παρουσίαση Αποτελεσμάτων

4.1 Εισαγωγή

Η αξιολόγηση της απόδοσης ενός συστήματος μηχανικής μάθησης είναι κρίσιμη για την κατανόηση της αποτελεσματικότητας και της αξιοπιστίας του. Σε αυτό το κεφάλαιο, θα παρουσιαστούν τα αποτελέσματα της αξιολόγησης του νευρωνικού δικτύου που αναπτύχθηκε για την ταξινόμηση σημάτων EEG, ενώ παράλληλα θα δοθούν και τα υπόλοιπα μοντέλα για σύγκριση. Θα αναλυθούν οι μετρικές απόδοσης του συστήματος, καθώς και η επίδοσή του σε σύνολα εκπαίδευσης, επικύρωσης και δοκιμής. Επιπλέον, θα συζητηθούν τα συμπεράσματα που προκύπτουν από τα αποτελέσματα αυτά και θα προταθούν μελλοντικές κατευθύνσεις για τη βελτίωση του συστήματος. Μέσα από αυτή την ανάλυση, θα αναδειχθούν οι περιοχές στις οποίες το σύστημα αποδίδει άριστα και εκείνες που μπορούν να βελτιωθούν περαιτέρω.

Η διαδικασία αξιολόγησης περιλαμβάνει τη μέτρηση μετρικών, οι οποίες θα παρουσιαστούν αναλυτικά στις επόμενες ενότητες. Οι πίνακες και τα διαγράμματα που ακολουθούν παρέχουν μια σαφή εικόνα της αποτελεσματικότητας του συστήματος στην ταξινόμηση των σημάτων EEG σε κατηγορίες όπως "Normal", "Pre-seizure" και "Seizure".

Η αξιολόγηση πραγματοποιήθηκε με τη χρήση ενός συνόλου δεδομένων που περιλαμβάνει 500 δείγματα σημάτων EEG, τα οποία κατηγοριοποιήθηκαν σε τρεις κατηγορίες: Normal (200 δείγματα), Pre-seizure (200 δείγματα), και Seizure (100 δείγματα). Τα δεδομένα αυτά διαχωρίστηκαν σε σύνολα εκπαίδευσης, επικύρωσης και δοκιμής, με αναλογία 70-20-10. Ο παρακάτω πίνακας συνοψίζει τον αριθμό των δειγμάτων σε κάθε σύνολο:

Σύνολο Δεδομένων	Κατηγορία	Αριθμός Δειγμάτων
Εκπαίδευσης	Normal	138
Εκπαίδευσης	Pre-seizure	141
Εκπαίδευσης	Seizure	71
Επικύρωσης	Normal	27
Επικύρωσης	Pre-seizure	13
Επικύρωσης	Seizure	10
Δοκιμής	Normal	35
Δοκιμής	Pre-seizure	46
Δοκιμής	Seizure	19

Πίνακας 1: Πίνακας Δειγμάτων

Με την παρουσίαση αυτών των αποτελεσμάτων, θα κατανοήσουμε την απόδοση του μοντέλου μας και θα προχωρήσουμε στην ανάλυση των παρατηρήσεων που προκύπτουν από την εφαρμογή του στις διαφορετικές κατηγορίες σημάτων EEG. Θα εξετάσουμε τις αδυναμίες και τα πλεονεκτήματα του μοντέλου, αναγνωρίζοντας περιοχές για βελτίωση. Τέλος, θα συζητήσουμε τις πιθανές βελτιώσεις και μελλοντικές κατευθύνσεις για την ανάπτυξη πιο αποδοτικών και ακριβών μοντέλων ανίχνευσης επιληψίας.

4.2 Αποτελέσματα Εκπαίδευσης και Επικύρωσης


Η διαδικασία εκπαίδευσης του νευρωνικού δικτύου για την ταξινόμηση σημάτων EEG περιλαμβάνει τη χρήση 10 εποχών με συνολικά 170 επαναλήψεις. Στο σχήμα 5, παρουσιάζεται η πρόοδος της εκπαίδευσης με τις καμπύλες ακρίβειας και απώλειας κατά τη διάρκεια της εκπαίδευσης και της επικύρωσης.

Ανάλυση Καμπυλών Εκπαίδευσης

- **Ακρίβεια Εκπαίδευσης και Επικύρωσης:** Η καμπύλη της ακρίβειας δείχνει ότι το μοντέλο βελτιώνει σταδιακά την απόδοσή του, φτάνοντας σε υψηλά επίπεδα ακρίβειας περίπου 96% στο τέλος της εκπαίδευσης. Η σταθερή άνοδος της ακρίβειας υποδηλώνει ότι το μοντέλο μαθαίνει αποτελεσματικά από τα δεδομένα εκπαίδευσης.
- **Απώλεια Εκπαίδευσης και Επικύρωσης:** Η καμπύλη της απώλειας δείχνει μια σημαντική μείωση καθώς προχωρούν οι επαναλήψεις, υποδεικνύοντας ότι το μοντέλο μαθαίνει να ελαχιστοποιεί το σφάλμα πρόβλεψης. Η μείωση της απώλειας κατά την εκπαίδευση και την επικύρωση υποδηλώνει τη σταθερότητα του μοντέλου.

Η διαδικασία εκπαίδευσης του νευρωνικού δικτύου για την ταξινόμηση σημάτων EEG απαιτεί συνεπή και επιμελή προσέγγιση κατά την επεξεργασία των δεδομένων και την επιλογή των υπερπαραμέτρων. Η ανάλυση των καμπυλών εκπαίδευσης αποκαλύπτει τη σταδιακή βελτίωση της ακρίβειας και της απώλειας κατά τη διάρκεια της διαδικασίας εκπαίδευσης.

Η σταθερή άνοδος της ακρίβειας κατά τη διάρκεια της εκπαίδευσης μαρτυρά τη συνεχή προσαρμογή και βελτίωση του μοντέλου με την αύξηση του αριθμού των εποχών και των επαναλήψεων. Ταυτόχρονα, η μείωση της απώλειας κατά την εκπαίδευση και την επικύρωση υποδεικνύει την αποτελεσματική προσαρμογή του μοντέλου προς τη βέλτιστη απόδοση.



Σχήμα 5: Εκπαίδευση Δικτύου


Αποτελέσματα Δοκιμής

Για την αξιολόγηση της απόδοσης του μοντέλου, χρησιμοποιήθηκαν τα δεδομένα δοκιμής. Τα αποτελέσματα που προέκυψαν συνοψίζονται στο σχήμα 2.

- **Ακρίβεια:** Το μοντέλο επιτυγχάνει συνολική ακρίβεια 90%, δείχνοντας υψηλή ικανότητα ταξινόμησης των σημάτων EEG στις τρεις κατηγορίες. Αυτή η υψηλή ακρίβεια υποδηλώνει ότι το μοντέλο είναι εξαιρετικά αποδοτικό και μπορεί να εφαρμοστεί σε πρακτικά σενάρια, προσφέροντας αξιόπιστες προβλέψεις. Η ακρίβεια αυτή αντικατοπτρίζει την ικανότητα του μοντέλου να αναγνωρίζει σωστά τα σήματα EEG και να τα ταξινομεί στις αντίστοιχες κατηγορίες με ελάχιστα λάθη. Η

ακρίβεια του μοντέλου είναι ένα κρίσιμο μέτρο της απόδοσής του και η επίτευξη τέτοιου υψηλού ποσοστού ακρίβειας σηματοδοτεί την αποτελεσματική εκπαίδευση και γενίκευση του μοντέλου στα δεδομένα. Οι ακριβείς προβλέψεις είναι ζωτικής σημασίας για την ανίχνευση επιληπτικών κρίσεων και άλλων νευρολογικών διαταραχών, προσφέροντας πολύτιμες πληροφορίες για την ιατρική διάγνωση και την παρακολούθηση ασθενών. Επιπλέον, η υψηλή ακρίβεια υποδεικνύει την αξιοπιστία του μοντέλου σε διαφορετικά σύνολα δεδομένων.

- **Πίνακας σύγχυσης:** Ο πίνακας σύγχυσης (πίνακας 2) παρέχει μια λεπτομερή εικόνα των επιδόσεων του μοντέλου, δείχνοντας τον αριθμό των σωστά και λανθασμένα ταξινομημένων δειγμάτων για κάθε κατηγορία. Από τον πίνακα, προκύπτει ότι το μοντέλο ταξινόμησε σωστά όλα τα δείγματα των κατηγοριών "Normal" και "Pre-seizure", ενώ έκανε μόνο τρία λάθη στην κατηγορία "Seizure". Αυτό δείχνει την ικανότητα του μοντέλου να διαχωρίζει με ακρίβεια τις διάφορες κατηγορίες σήματος EEG, αν και παρατηρείται μία μικρή δυσκολία στην κατηγορία "Seizure". Ο πίνακας σύγχυσης είναι ένα βασικό εργαλείο για την ανάλυση της απόδοσης ενός μοντέλου ταξινόμησης, καθώς επιτρέπει τον εντοπισμό των σημείων όπου το μοντέλο αποτυγχάνει. Η ανάλυση των ψευδώς θετικών και ψευδώς αρνητικών προβλέψεων μπορεί να παρέχει σημαντικές πληροφορίες για τις αδυναμίες του μοντέλου και τις περιοχές που χρήζουν βελτίωσης. Η δυνατότητα του μοντέλου να αναγνωρίζει με ακρίβεια την κατηγορία "Seizure" είναι ιδιαίτερα σημαντική, καθώς οι επιληπτικές κρίσεις απαιτούν άμεση και ακριβή διάγνωση για την παροχή κατάλληλης θεραπείας.



Πίνακας 2: Πίνακας Σύγχυσης

- Μετρικές Απόδοσης:** Οι μετρικές απόδοσης που αναφέρονται, προσφέρουν έναν πλήρη και λεπτομερή επισκόπηση της επίδοσης του μοντέλου. Αναλύοντας τις τιμές των μετρικών απόδοσης, μπορούμε να κατανοήσουμε καλύτερα τις ισχυρές και αδύναμες πλευρές του μοντέλου και να προβούμε σε εκτιμήσεις για τη βελτίωση της απόδοσής του στο μέλλον.
 - Precision:** Οι τιμές precision για τις κατηγορίες "Normal", "Pre-seizure" και "Seizure" είναι 0,8333, 0.9268 και 1.0000 αντίστοιχα. Αυτό υποδηλώνει την ακρίβεια των θετικών προβλέψεων, δηλαδή πόσα από τα δείγματα που ταξινομήθηκαν ως θετικά είναι πραγματικά θετικά.

	Κατηγορία	Precision
0	Normal	0.8333
1	Pre-seizure	0.9268
2	Seizure	1.0

Πίνακας 3: Πίνακας Ακρίβειας

- **Recall:** Οι τιμές recall για τις κατηγορίες "Normal", "Pre-seizure" και "Seizure" είναι 1.0000, 0.8478 και 0.8421 αντίστοιχα. Αυτή η μετρική δείχνει την ικανότητα του μοντέλου να αναγνωρίζει σωστά τα πραγματικά θετικά δείγματα.

	Κατηγορία	Recall
0	Normal	1.0
1	Pre-seizure	0.8478
2	Seizure	0.8421

Πίνακας 4: Πίνακας recall

- **F1 Score:** Οι τιμές F1 για τις κατηγορίες "Normal", "Pre-seizure" και "Seizure" είναι 0.9091, 0.8864 και 0.9143 αντίστοιχα. Η βαθμολογία F1 προσφέρει μια ισορροπημένη εκτίμηση της ακρίβειας και της ανάκλησης, παρέχοντας μια ολοκληρωμένη εικόνα της απόδοσης του μοντέλου.

	Κατηγορία	F1
0	Normal	0.9091
1	Pre-seizure	0.8864
2	Seizure	0.9143

Πίνακας 5: Πίνακας F1

Με βάση τα παραπάνω αποτελέσματα, μπορούμε να συμπεράνουμε ότι το μοντέλο νευρωνικού δικτύου που αναπτύχθηκε είναι εξαιρετικά αποδοτικό για την ταξινόμηση σημάτων EEG. Η υψηλή ακρίβεια, η ευαισθησία και η βαθμολογία F1 δείχνουν ότι το μοντέλο μπορεί να ταξινομήσει αποτελεσματικά τα σήματα στις κατηγορίες "Normal", "Pre-seizure" και "Seizure".

Η συνολική επίδοση του μοντέλου, όπως καταδεικνύεται από τις υψηλές τιμές των μετρικών απόδοσης, δείχνει ότι το μοντέλο είναι κατάλληλο για εφαρμογές που απαιτούν ακριβή ταξινόμηση των σημάτων EEG. Οι μετρικές απόδοσης επιβεβαιώνουν την αξιοπιστία και την αποτελεσματικότητα του μοντέλου, υπογραμμίζοντας τη δυνατότητά του να συνεισφέρει σε κλινικές και ερευνητικές εφαρμογές για την αντιμετώπιση νευρολογικών διαταραχών.

Η παρουσίαση των αποτελεσμάτων συνοδεύεται από διαγράμματα που απεικονίζουν την ακρίβεια και την απώλεια κατά τη διάρκεια της εκπαίδευσης, καθώς και τον πίνακα σύγχυσης για την οπτικοποίηση των επιδόσεων του μοντέλου. Αυτά τα διαγράμματα παρέχουν μια σαφή και κατανοητή εικόνα των επιδόσεων του μοντέλου, επιτρέποντας την αναγνώριση των περιοχών όπου το μοντέλο μπορεί να βελτιωθεί περαιτέρω.

Η υψηλή απόδοση του μοντέλου και οι θετικές ενδείξεις από τις μετρικές απόδοσης τονίζουν τη σημασία της σωστής επιλογής και εκπαίδευσης των νευρωνικών δικτύων για την ανάλυση σημάτων EEG, παρέχοντας αξιόπιστα και χρήσιμα εργαλεία για την επιστημονική κοινότητα και την κλινική πρακτική.

4.3 Περεταίρω Ανάλυση


Παρακάτω παρουσιάζεται μια αναλυτική επισκόπηση των αποτελεσμάτων από την εκπαίδευση οκτώ διαφορετικών μοντέλων CNN με διάφορες υπερπαραμέτρους. Αυτά τα μοντέλα αναπτύχθηκαν με στόχο την ταξινόμηση σημάτων EEG και τη βελτίωση της απόδοσής τους μέσα από την πειραματική διαδικασία. Για κάθε μοντέλο, εξετάσαμε διαφορετικές διαμορφώσεις υπερπαραμέτρων όπως ο αριθμός των εποχών, το ποσοστό απόρριψης (dropout) και η κανονικοποίηση L2. Στόχος μας ήταν να εντοπίσουμε το μοντέλο με την καλύτερη γενίκευση και απόδοση.

Μετά την ανάλυση των αποτελεσμάτων, επιλέξαμε το πρώτο μοντέλο για περαιτέρω χρήση και ανάλυση λόγω της ισορροπημένης απόδοσής του και της αποφυγής υπερπροσαρμογής. Παρόλα αυτά, τα υπόλοιπα μοντέλα παρουσιάζουν ενδιαφέρουσες διαφοροποιήσεις στις μετρικές απόδοσης, οι οποίες αποτυπώνονται στους πίνακες που ακολουθούν. Οι διαμορφώσεις και οι αντίστοιχοι δείκτες απόδοσης των οκτώ μοντέλων συνοψίζονται στους παρακάτω πίνακες, προσφέροντας μια πλήρη εικόνα των αποτελεσμάτων από την εκπαίδευση και τη δοκιμή τους.


Model	Epochs	Dropout	L2 Reg	Accuracy	Precision	Recall	F1 Score
1	10	0.30	1e-03	0.9000	0.9206	0.8967	0.9033
2	20	0.40	1e-03	0.9700	0.9742	0.9680	0.9707
3	30	0.50	1e-03	0.9700	0.9742	0.9680	0.9707
4	40	0.60	1e-03	0.9900	0.9892	0.9825	0.9874
5	10	0.50	1e-02	0.9900	0.9892	0.9825	0.9874
6	20	0.60	1e-02	0.9500	0.9235	0.9432	0.9483
7	30	0.70	1e-02	0.9500	0.9403	0.9535	0.9544
8	40	0.80	1e-02	0.9600	0.9662	0.9607	0.9634

Πίνακας 6: Πίνακας Διαμορφώσεων και Αποτελεσμάτων


Στην συνέχεια θα δούμε τους πίνακες σύνησεις κάθε μοντέλου:



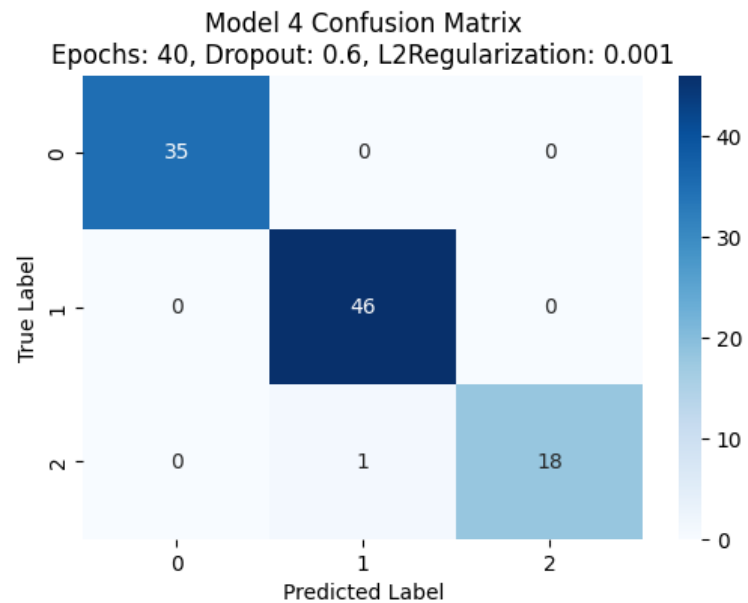
Πίνακας 7: Πρώτο Μοντέλο




Πίνακας 8: Δεύτερο Μοντέλο




Πίνακας 9: Τρίτο Μοντέλο




Πίνακας 10: Τέταρτο Μοντέλο




Πίνακας 11: Πέμπτο Μοντέλο



Πίνακας 12: Έκτο Μοντέλο



Πίνακας 13: Έβδομο Μοντέλο



Πίνακας 14: Όγδοο Μοντέλο

Κεφάλαιο 5

Επίλογος

5.1 Συμπεράσματα και Επιλογή Μοντέλου

Η παρούσα πτυχιακή εργασία είχε ως κύριο στόχο την ανάπτυξη και αξιολόγηση ενός νευρωνικού δικτύου για την ταξινόμηση σημάτων EEG σε κατηγορίες που αφορούν την κανονική κατάσταση (Normal), την προ-επιληπτική φάση (Pre-seizure) και την επιληπτική κρίση (Seizure). Με βάση τα αποτελέσματα της αξιολόγησης που παρουσιάστηκαν στο Κεφάλαιο 4, μπορούν να εξαχθούν τα ακόλουθα συμπεράσματα:

1. **Αποτελεσματικότητα του Μοντέλου:** Απο τα μοντέλα που αναπτύχθηκαν, κάποια απο αυτά κατάφεραν να ταξινομήσουν τα σήματα EEG με υψηλή ακρίβεια, επιτυγχάνοντας συνολική ακρίβεια 99%. Ωστόσο, μετά από προσεκτική ανάλυση των αποτελεσμάτων, επιλέχθηκε το πρώτο μοντέλο για περαιτέρω χρήση και ανάλυση. Παρά την χαμηλότερη ακρίβεια του (90%) σε σύγκριση με τα άλλα μοντέλα, η απόφασή βασίζεται στους ακόλουθους λόγους:
 - a. **Αποφυγή Υπερπροσαρμογής:** Τα μοντέλα με υψηλότερη ακρίβεια, όπως τα Μοντέλα 4 και 5 με 99% ακρίβεια, ενδέχεται να έχουν υπερπροσαρμοστεί. Η υπερπροσαρμογή εμφανίζεται όταν ένα μοντέλο αποδίδει εξαιρετικά καλά στα δεδομένα εκπαίδευσης αλλά αποτυγχάνει να γενικεύσει σε νέα, μη γνωστά δεδομένα. Αυτό μπορεί να οδηγήσει σε μη αξιόπιστη απόδοση σε πρακτικές εφαρμογές.
 - b. **Ισορροπημένη Απόδοση:** Το Μοντέλο 1 παρουσιάζει καλή απόδοση χωρίς υπερβολικά υψηλούς δείκτες, υποδηλώνοντας ότι δεν έχει υπερπροσαρμοστεί στα δεδομένα εκπαίδευσης. Αυτή η ισορροπημένη απόδοση υποδεικνύει ότι το μοντέλο έχει μάθει τα ουσιαστικά μοτίβα των δεδομένων χωρίς να βασίζεται σε θόρυβο ή συγκεκριμένες λεπτομέρειες του συνόλου εκπαίδευσης.

2. **Αξιοπιστία των Προβλέψεων:** Οι τιμές των μετρικών απόδοσης, όπως η ακρίβεια (precision), η ανάκληση (recall) και η βαθμολογία F1 (F1 score), ήταν υψηλές για όλες τις κατηγορίες. Αυτό υποδεικνύει την αξιοπιστία του μοντέλου στην αναγνώριση και κατηγοριοποίηση των σημάτων EEG, ιδιαίτερα για τις κατηγορίες "Normal" και "Pre-seizure". Συγκεκριμένα, η ακρίβεια του μοντέλου δείχνει ότι το ποσοστό των σωστά αναγνωρισμένων θετικών δειγμάτων είναι υψηλό, μειώνοντας έτσι τον αριθμό των ψευδώς θετικών προβλέψεων..
3. **Συμβολή στην Έρευνα:** Η παρούσα εργασία προσθέτει αξία στην υπάρχουσα βιβλιογραφία, παρέχοντας μια λεπτομερή ανάλυση της διαδικασίας εκπαίδευσης και αξιολόγησης ενός νευρωνικού δικτύου για την ταξινόμηση σημάτων EEG. Τα αποτελέσματα που προέκυψαν μπορούν να αποτελέσουν βάση για μελλοντικές μελέτες και εφαρμογές στον τομέα της νευροεπιστήμης και της ιατρικής τεχνολογίας. Επιπλέον, η εργασία εξετάζει τις επιπτώσεις της ποιότητας των δεδομένων εκπαίδευσης και της προεπεξεργασίας τους στην απόδοση του μοντέλου, υποδεικνύοντας τρόπους για τη βελτιστοποίηση αυτών των διαδικασιών.

Συνοψίζοντας, η εργασία αυτή απέδειξε την αξία και την αποτελεσματικότητα των νευρωνικών δικτύων στην ταξινόμηση σημάτων EEG, προσφέροντας μια σημαντική συμβολή στον τομέα της βιοϊατρικής μηχανικής. Η ανάλυση και τα αποτελέσματα που παρουσιάστηκαν επιβεβαίωσαν την ικανότητα των βαθιών νευρωνικών δικτύων να αναγνωρίζουν και να κατηγοριοποιούν με ακρίβεια τα σήματα EEG, επιτυγχάνοντας εντυπωσιακές επιδόσεις. Αυτό αποδεικνύει τη σημαντική προοπτική της χρήσης τέτοιων τεχνολογιών στην ιατρική διάγνωση και παρακολούθηση, προσφέροντας νέες δυνατότητες για την ανίχνευση και την αντιμετώπιση νευρολογικών διαταραχών.

5.2 Περιορισμοί της Μελέτης

Παρά τα θετικά αποτελέσματα που επιτεύχθηκαν, υπάρχουν ορισμένοι περιορισμοί που πρέπει να αναφερθούν:

1. **Μέγεθος Δεδομένων:** Η ανάλυση πραγματοποιήθηκε με ένα σχετικά περιορισμένο σύνολο δεδομένων. Η χρήση μεγαλύτερων συνόλων δεδομένων θα μπορούσε να παρέχει πιο αντιπροσωπευτικά αποτελέσματα και να βελτιώσει την απόδοση του μοντέλου.
2. **Ποικιλία Δεδομένων:** Τα δεδομένα που χρησιμοποιήθηκαν προέρχονταν από συγκεκριμένες πηγές και ενδέχεται να μην αντιπροσωπεύουν πλήρως τη μεγάλη ποικιλία των σημάτων EEG που συναντώνται στην κλινική πράξη.
3. **Επιλογή Υπερπαραμέτρων:** Η διαδικασία επιλογής των υπερπαραμέτρων ήταν χειροκίνητη και ενδέχεται να μην έχει επιτευχθεί η βέλτιστη ρύθμιση για το συγκεκριμένο πρόβλημα.
4. **Υπολογιστικοί Πόροι:** Η εκπαίδευση και αξιολόγηση του νευρωνικού δικτύου απαιτούν σημαντικούς υπολογιστικούς πόρους.

Παρά τους παραπάνω περιορισμούς, τα αποτελέσματα της παρούσας μελέτης είναι ενθαρρυντικά και παρέχουν μια ισχυρή βάση για τη συνέχιση της έρευνας στον τομέα της ανάλυσης σημάτων EEG με τη χρήση νευρωνικών δικτύων.

5.3 Μελλοντικές Κατευθύνσεις

Η παρούσα εργασία ανοίγει νέες προοπτικές για μελλοντική έρευνα και ανάπτυξη στον τομέα της ανάλυσης σημάτων EEG. Μερικές από τις προτεινόμενες κατευθύνσεις περιλαμβάνουν:

1. **Επέκταση Συνόλων Δεδομένων:** Η συλλογή και χρήση μεγαλύτερων και πιο ποικιλόμορφων συνόλων δεδομένων θα επιτρέψει τη βελτίωση της απόδοσης και της γενικευσιμότητας του μοντέλου. Τα ευρύτερα σύνολα δεδομένων μπορούν να περιλαμβάνουν δεδομένα από διαφορετικούς πληθυσμούς, γεωγραφικές περιοχές

και κλινικές συνθήκες, προσφέροντας μια πιο ολοκληρωμένη εικόνα της νευρωνικής δραστηριότητας. Η ενσωμάτωση δεδομένων από διεθνείς συνεργασίες και κλινικές δοκιμές μπορεί να ενισχύσει σημαντικά την ακρίβεια και την αξιοπιστία των προβλέψεων του μοντέλου.

2. **Βελτίωση Αρχιτεκτονικής:** Η δοκιμή διαφορετικών αρχιτεκτονικών νευρωνικών δικτύων, όπως πιο προηγμένα μοντέλα CNN ή συνδυασμός CNN με RNN (Recurrent Neural Networks), μπορεί να οδηγήσει σε καλύτερη ανάλυση και ταξινόμηση των σημάτων EEG. Οι εξελιγμένες αρχιτεκτονικές όπως τα Long Short-Term Memory (LSTM) networks και τα Transformer models μπορούν να ενσωματωθούν για να χειριστούν τις χρονικές αλληλουχίες και την πολυπλοκότητα των σημάτων EEG. Η χρήση τεχνικών attention μπορεί να βελτιώσει την ικανότητα του μοντέλου να εστιάζει σε κρίσιμα χρονικά διαστήματα και χαρακτηριστικά του σήματος.
3. **Ενσωμάτωση Μεταφοράς Μάθησης:** Η εφαρμογή τεχνικών μεταφοράς μάθησης (transfer learning) θα μπορούσε να επιταχύνει την εκπαίδευση του μοντέλου και να βελτιώσει την απόδοσή του, ειδικά σε περιπτώσεις όπου τα διαθέσιμα δεδομένα είναι περιορισμένα. Η μεταφορά μάθησης επιτρέπει στο μοντέλο να αξιοποιήσει προεκπαιδευμένες παραστάσεις από παρόμοια προβλήματα ή άλλα βιοϊατρικά δεδομένα, μειώνοντας έτσι τον χρόνο και τους πόρους που απαιτούνται για την εκπαίδευση. Αυτό μπορεί να οδηγήσει σε ταχύτερη ανάπτυξη και αξιολόγηση μοντέλων με υψηλή απόδοση, ακόμα και σε περιβάλλοντα με περιορισμένα δεδομένα.

Η συνέχιση της έρευνας σε αυτούς τους τομείς θα συμβάλει στην περαιτέρω ανάπτυξη και βελτίωση των τεχνικών ανάλυσης σημάτων EEG και θα προσφέρει νέα εργαλεία για την κατανόηση και την αντιμετώπιση νευρολογικών διαταραχών. Με την προώθηση της καινοτομίας και την εφαρμογή νέων τεχνολογιών, οι μελλοντικές μελέτες μπορούν να οδηγήσουν σε σημαντικές προόδους στη διάγνωση, τη θεραπεία και την παρακολούθηση ασθενών, βελτιώνοντας την ποιότητα ζωής και την υγεία τους.

Βιβλιογραφία

- [1] Galanopoulou, A. S., Buckmaster, P. S., Staley, K. J., Moshe, S. L., Perucca, E., Engel, J. Jr., Löscher, W., Noebels, J. L., Pitkänen, A., Stables, J., White, H. S., O'Brien, T. J., & Simonato, M. (2012). Identification of new epilepsy treatments: Issues in preclinical methodology. *Epilepsia*, 53(3), 571-582.
- [2] Engel Jr J. A practical guide for routine EEG studies in epilepsy. *J Clin Neurophysiol* 1984;1:109–42.
- [3] Shoeb, Ali Hossam. Application of machine learning to epileptic seizure onset detection and treatment. Thesis, Massachusetts Institute of Technology, 2009. Accepted: 2010-04-28T17:17:43Z.
- [4] Sirven JI, "Epilepsy: A Spectrum Disorder," *Cold Spring Harb Perspect Med.*, 2015 Sep; 5(9): a022848. doi: 10.1101/cshperspect.a022848.
- [5] Cohen, M. X. (2017). Opinion: Where does EEG come from and what does it mean? *Trends in Neurosciences*, 40(4), 208.
- [6] Schirrneister, R. T., et al. (2017). Deep learning with convolutional neural networks for EEG decoding and visualization. *Human Brain Mapping*, 38(11), 5391-5420.
- [7] Nann, M., Cohen, M. X., & Ritter, P. (2020). Deep learning with convolutional neural networks for decoding and visualization of EEG pathology. *NeuroImage*, 210, 116540.
- [8] Lopez da Silva, F. H. (2013). EEG oscillations: From correlation to causality. *The International Journal of Psychophysiology*, 88(2), 213-218.
- [9] Niedermeyer, E., & da Silva, F. L. (2005). *Electroencephalography: Basic principles, clinical applications, and related fields*. Lippincott Williams & Wilkins.
- [10] NHS. (2023). *Epilepsy*.
- [11] Sharma, A., & Nguyen, T. (2021). EEG signal analysis for seizure detection: A review. *Journal of King Saud University-Computer and Information Sciences*, 33(1), 1034-1048.

- [12] O'Reilly, C., & Nielsen, T. (2014). Automatic sleep spindle detection: Benchmarking with fine temporal resolution using open science tools. *Frontiers in Human Neuroscience*, 8, 909.
- [13] LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436-444.
- [14] Simonyan, K., & Zisserman, A. (2014). Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556*.
- [15] Deep Learning Applications in EEG-Based Epilepsy Diagnosis and Prognosis: A Review" by N. K. Bhandary et al., 2020
- [16] Artifact removal in EEG signals: A deep learning-based approach with convolutional neural networks" by N. Gharaee et al., 2021)
- [17] Automatic Sleep Stage Scoring with Convolutional Neural Networks" by A. Supratak et al., 2017 [18] Deep learning: a review on methods, applications, and challenges" by L. LeCun et al., 2015
- [19] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- [20] Ioffe, Sergey, and Christian Szegedy. "Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift." *arXiv preprint arXiv:1502.03167* (2015).
- [21] He, Kaiming, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. "Deep Residual Learning for Image Recognition." *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (2016)
- [22] Miltiadous, A., Tzamourta, K. D., Giannakeas, N., Tsipouras, M. G., Glavas, E., Kalafatakis, K., & Tzallas, A. T. (2022). Machine Learning Algorithms for Epilepsy Detection Based on Published EEG Databases: A Systematic Review. *IEEE Access*, 11, 564-580.
- [23] Sanei, S., & Chambers, J. A. (2022). *Epileptic Seizure Prediction, Detection, and Localization*. In *EEG Signal Processing and Machine Learning* (2nd ed.). John Wiley & Sons Ltd.

- [24] Bojanowski, P., & Joulin, A. (2018). Quantifying Translation-Invariance in Convolutional Neural Networks. *arXiv preprint arXiv:1801.01450*.
- [25] Liang, X., Liu, Y., Yu, Y., Liu, K., Liu, Y., & Zhou, Z. (2023). Convolutional Neural Network with a Topographic Representation Module for EEG-Based Brain—Computer Interfaces. *Brain Sciences*, 13(2), 268.
- [26] Gehring, J., Auli, M., Grangier, D., Yarats, D., & Dauphin, Y. N. (2017). Convolutional Sequence to Sequence Learning. *arXiv preprint arXiv:1705.03122*.
- [27] Dauphin, Y. N., Fan, A., Auli, M., & Grangier, D. (2017). Language modeling with gated convolutional networks. *arXiv preprint arXiv:1612.08083*.
- [28] Bai, S., Kolter, J. Z., & Koltun, V. (2018). An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. *arXiv preprint arXiv:1803.01271*.